أكاديمية علو

وزارة الاتصالات وتقنية المعلومات
MINISTRY OF COMMUNICATIONS AND INFORMATION TECHNOLOGY

عام الذكاء الاصطناعي
THE YEAR OF ARTIFICIAL INTELLIGENCE 2026

صيفك ذكي 2026

معسكر هندسة الذكاء الاصطناعي (AIEP) المؤهّل للتوظيف

الأسبوع ٢ - اليوم الأول

أكاديمية علو

إرشادات الجلسات

أنتم المدرّب الأهم

إجاباتكم قد تكون أحياناً أهم من محتوانا لزملائكم، لذلك لا تتردّدون في الإجابة على بعض، وبرضو ما يمنع تعبّرونا وتجاوبوا على أسئلتنا

ما فيه سؤال غلط

ما يهمّ وش تخصصكم أو مدى خبرتكم، كلنا جينا نتعلّم هنا من بعض، لذلك لا تتردّدون في السؤال، لأنه ما فيه سؤال غلط

0 تفاعل = 0 فائدة

التفاعل أساس الجلسة، خلوكم جاهزين تجاوبون على أسئلة وتشتغلون مع بعض في الجلسة

سمّينا بالله ؟

تحليل البيانات الاستكشافي - EDA

الأسبوع ٢ - اليوم الأول
معسكر هندسة الذكاء الإصطناعي (AIEP)

أكاديمية علو

موضوعات الجلسة

1 ما هي البيانات؟ أنواع البيانات

2 تحليل البيانات الاستكشافي - EDA

3 تنظيف البيانات (Data Cleaning)

نشاط 1 | ⏳ دقيقة واحدة

ادّعى خمسة طلاب أنهم حضروا محاضرة الذكاء الاصطناعي التي بدأت الساعة 10:00 صباحًا.
لكن نظام الحضور تعطّل، ولم يتبقَّ سوى بيانات من أنظمة أخرى في الجامعة.
أحد الطلاب من المستحيل أن يكون قد حضر المحاضرة فعليًا. من هو؟

الطالب	مسح QR داخل القاعة	رفع الواجب	دخول المكتبة	شراء من الكافتيريا	اتصال Wi-Fi
A	10:01	12:04	11:15	9:42	9:57
B	10:02	11:48	12:10	9:35	10:03
C	10:00	12:15	9:30	11:20	9:55
D	10:01	11:50	10:06	10:04	9:58
E	10:03	12:02	11:40	9:44	10:00

الإجابة:

- مسح رمز الـ QR داخل القاعة الساعة 10:01
- اشترى من الكافتيريا الساعة 10:04
- دخل المكتبة الساعة 10:06

وهذا التسلسل غير ممكن زمنيًا ومكانيًا.
الفكرة الأساسية هي أن كل قيمة منفردة تبدو طبيعية، لكن عند ربط عدة مصادر بيانات معًا يظهر التناقض.

ما هي البيانات؟ أنواع البيانات

الثقافة البيانية (Data Literacy)

- البيانات هي مجموعة من الحقائق والملاحظات الأولية.
- البيانات هي الوقود الذي تعتمد عليه نماذج تعلّم الآلة.
- تُستخدم البيانات لتدريب نموذج تعلّم الآلة والتحقق من أدائه واختباره.

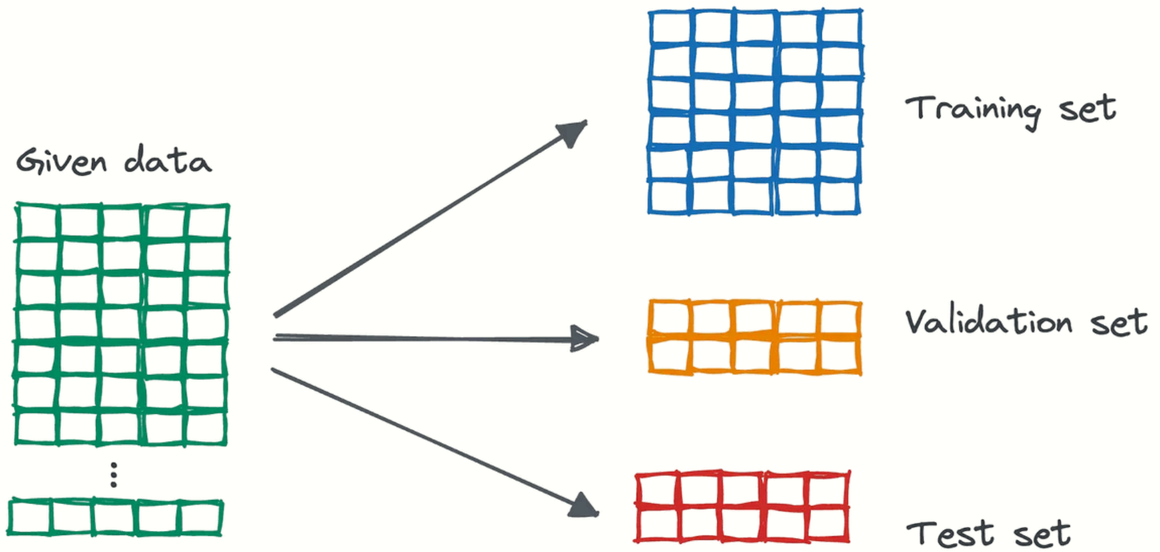

أنواع البيانات

- البيانات الجدولية (Tabular Data)

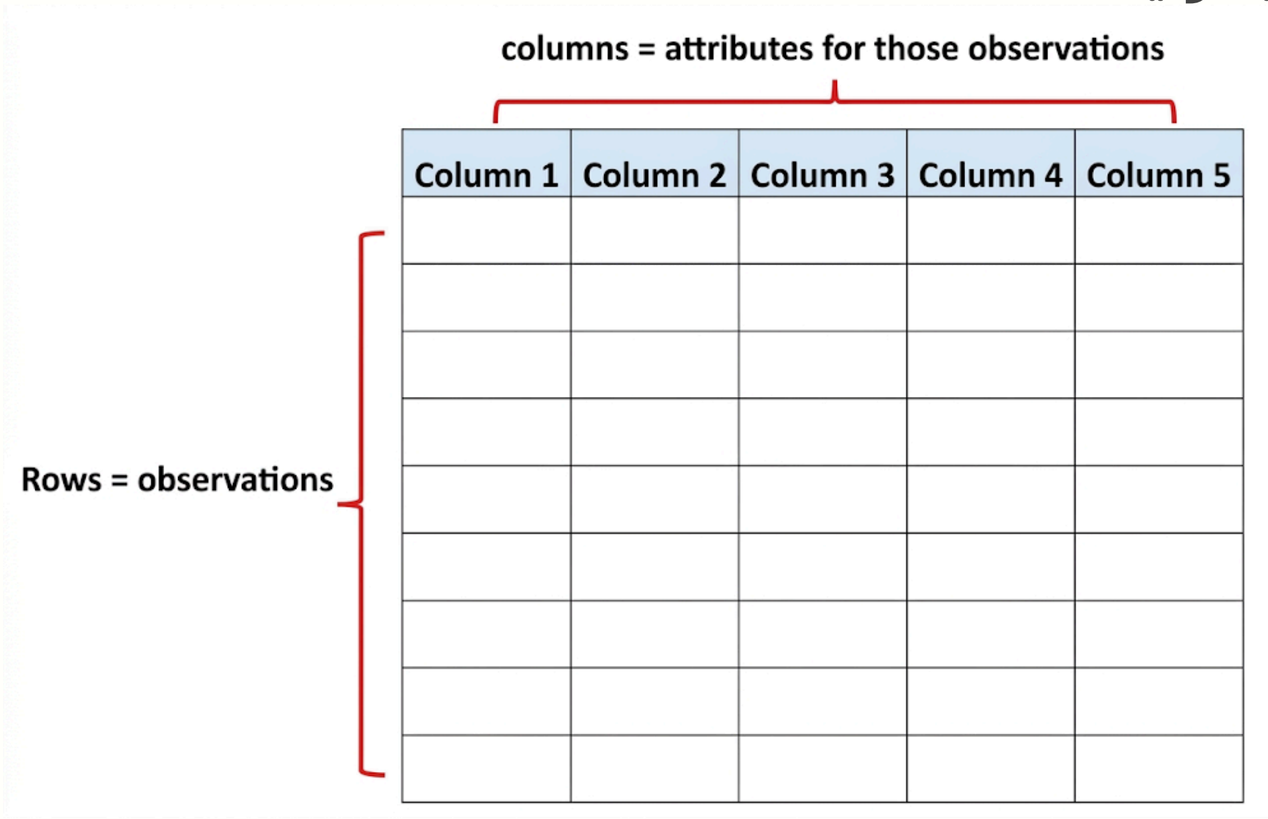

البيانات الجدولية (Tabular Data)

- تُعد من أكثر أنواع البيانات شيوعًا في تعلّم الآلة.
- تعمل بشكل جيد مع العديد من خوارزميات تعلّم الآلة التقليدية.

Size (m²)	Rooms	Type	Parking	Price (SAR)
120	3	Apartment	1	950,000
180	4	Villa	2	1,350,000
140	3	Apartment	1	980,000
220	5	Villa	3	1,850,000
160	4	Townhouse	2	1,200,000

البيانات التسلسلية (Time series)

- بيانات يتم جمعها عبر الزمن وبترتيب زمني متسلسل.
- الترتيب مهم، لأن الماضي قد يؤثر على المستقبل.

Date	Open Price (SAR)	Close Price (SAR)	High	Low	Volume
Jan 1, 2025	128.5	130.1	131.2	127.8	1.2M
Jan 2, 2025	130.15	129.3	131	128.5	1.0M
Jan 3, 2025	129.4	132.6	133.1	129.1	1.5M
Jan 4, 2025	132.7	131.8	134.2	131.1	1.3M
Jan 5, 2025	131.9	135.5	136	131.4	1.6M

أنواع البيانات

- البيانات التسلسلية (Time series)

أكاديمية علو

البيانات التسلسلية (Time series)

- درجات الحرارة اليومية

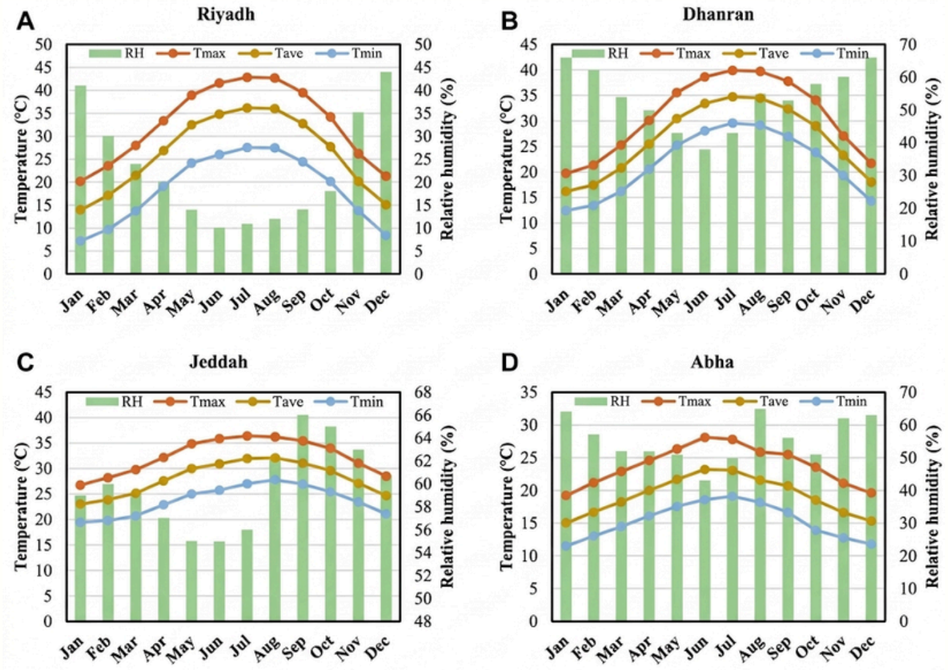

- سوق الأسهم

أكاديمية علو

البيانات التسلسلية (Time series)

- ضغط الدم

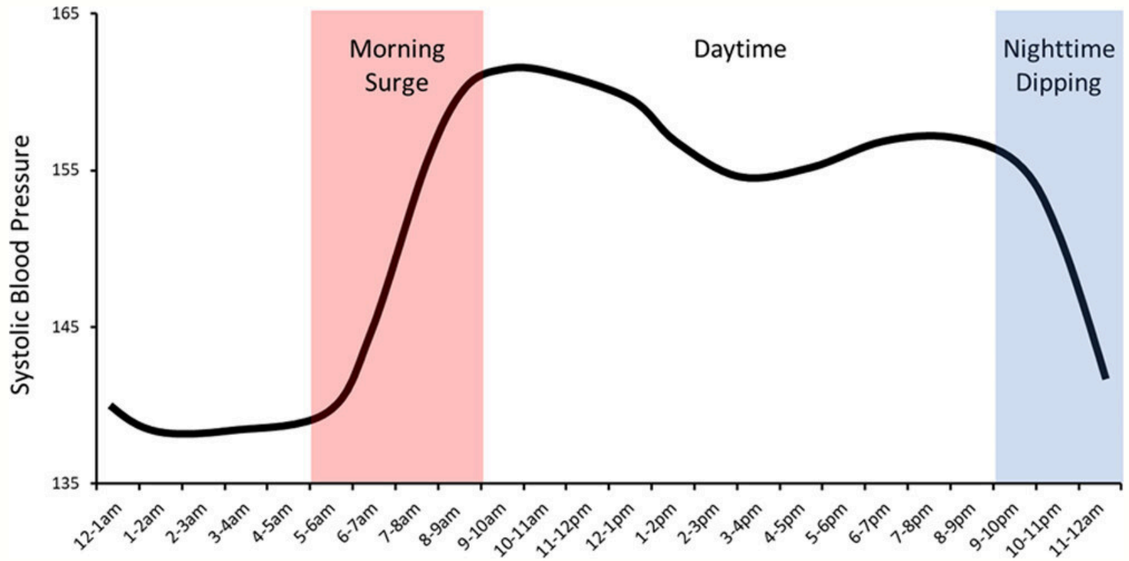

- بيانات أجهزة الاستشعار

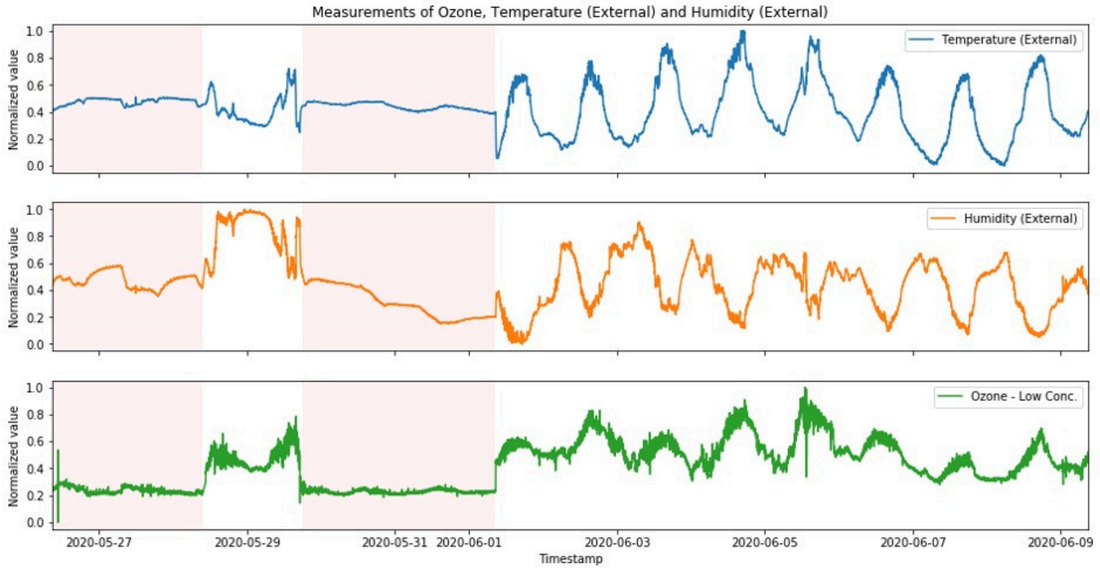

أنواع البيانات

- بيانات الصور (Image Data)

بيانات الصور (Image Data)

- تتكوّن الصور من وحدات بكسل (Pixels)، حيث يحتوي كل بكسل على معلومات محددة عن اللون وشدة الإضاءة.

- الصور الملوّنة

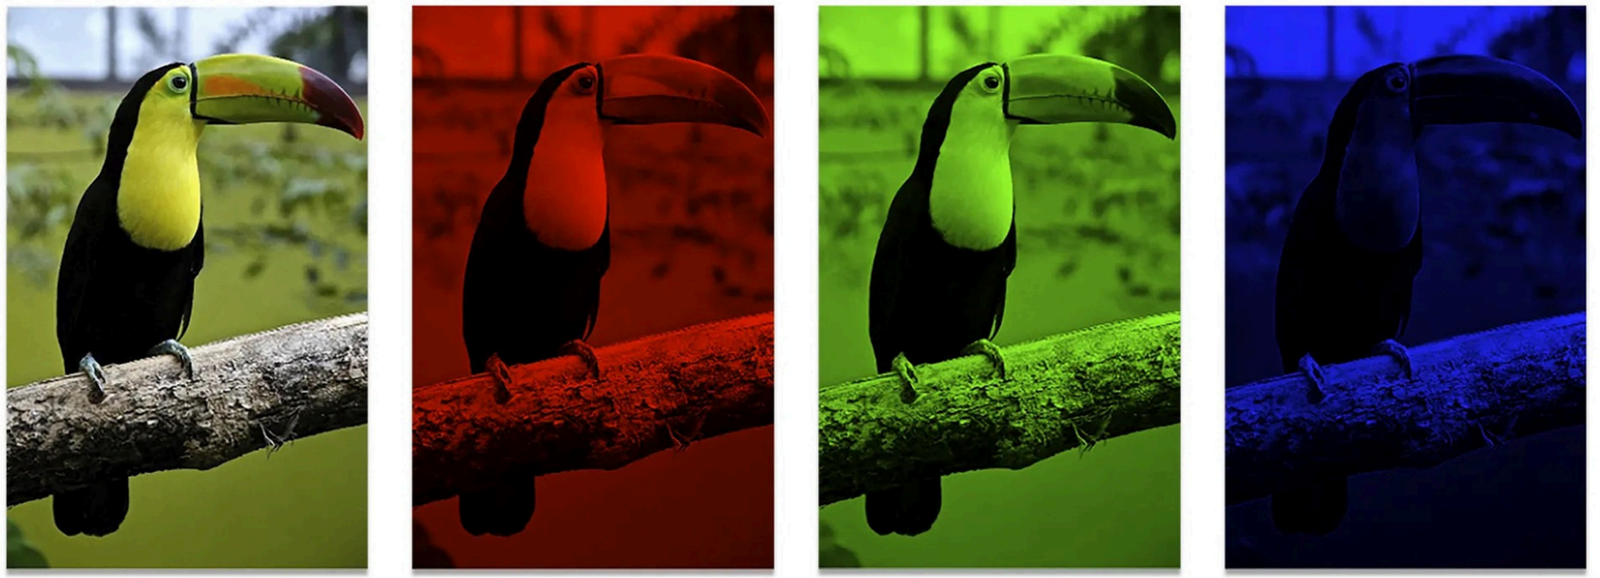

بيانات الصور (Image Data)

- تتكوّن الصور من وحدات بكسل (Pixels)، حيث يحتوي كل بكسل على معلومات محددة عن اللون وشدة الإضاءة.

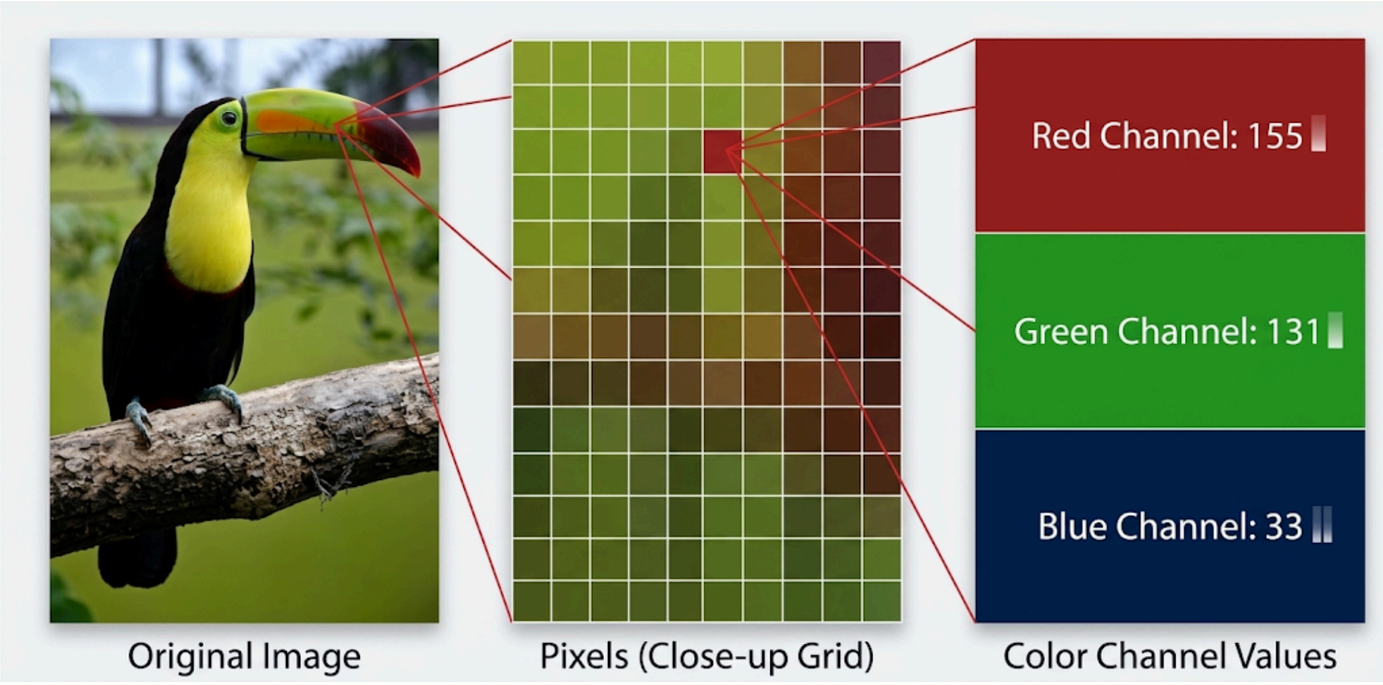

- الصور الملوّنة

بيانات الصور (Image Data)

- الصور بالأبيض والأسود
- الصور الرمادية

LOW-RESOLUTION FACE (GREYSCALE PIXELS)

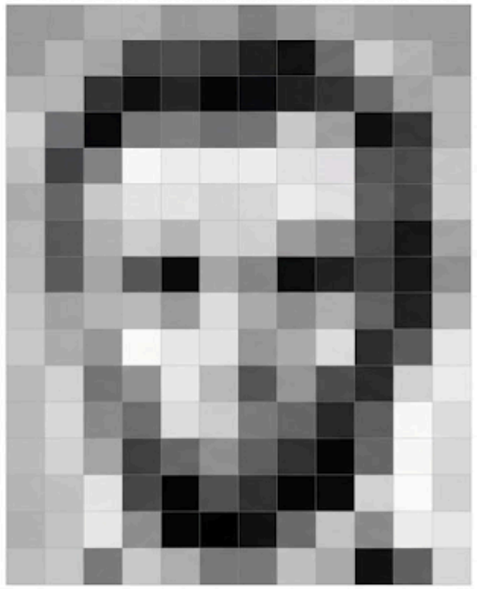

NUMERICAL DATA MATRIX (COORDINATED HEAT MAP)

157	153	174	168	150	152	129	151	172	161	155	156
155	162	163	74	75	62	33	17	110	210	180	154
180	180	50	14	34	6	10	33	48	106	188	181
206	108	5	124	131	111	120	204	166	15	56	160
194	68	137	251	237	228	239	228	227	87	71	201
173	106	207	233	233	214	220	239	228	98	74	206
188	8	179	209	185	215	211	188	139	75	20	169
189	97	166	84	10	168	211	118	139	75	20	148
199	168	181	193	158	227	178	143	182	82	22	190
205	174	186	252	236	231	146	178	228	43	65	234
190	216	116	149	236	187	66	180	79	38	218	241
190	224	147	108	227	210	127	102	38	101	255	224
190	214	173	66	103	143	96	60	2	109	249	215
187	196	226	75	1	0	1	47	0	217	255	211
183	202	237	145	0	0	0	12	108	200	243	236
195	206	123	207	177	121	223	200	175	13	86	218

NUMERICAL VALUE MATRIX (TEXT ONLY)

157	153	174	168	152	129	151	172	161	155	156
155	162	74	75	62	33	17	110	210	180	154
180	180	50	14	34	10	33	48	106	188	181
206	108	5	124	131	120	204	166	15	56	160
194	68	137	251	237	228	228	227	87	71	201
173	106	207	233	214	220	239	228	98	74	206
188	8	179	209	185	211	188	139	75	20	169
189	97	166	84	168	134	11	31	62	22	148
199	168	181	193	227	178	143	182	106	36	190
205	174	186	252	231	146	178	228	43	65	234
190	216	116	149	236	187	180	79	38	218	241
190	224	147	108	227	127	102	38	101	255	224
190	214	173	66	103	143	60	2	109	249	215
187	196	226	75	1	1	47	0	217	255	211
183	202	237	145	0	0	12	108	200	243	236
195	206	123	207	177	223	200	175	13	86	218

بيانات الصور (Image Data)

البيانات الجدولية = صفوف وأعمدة منظّمة

Size (m²)	Rooms	Type	Parking	Price (SAR)
120	3	Apartment	1	950,000
180	4	Villa	2	1,350,000
140	3	Apartment	1	980,000
220	5	Villa	3	1,850,000
160	4	Townhouse	2	1,200,000

الصور = شبكة غير منظّمة من وحدات البكسل

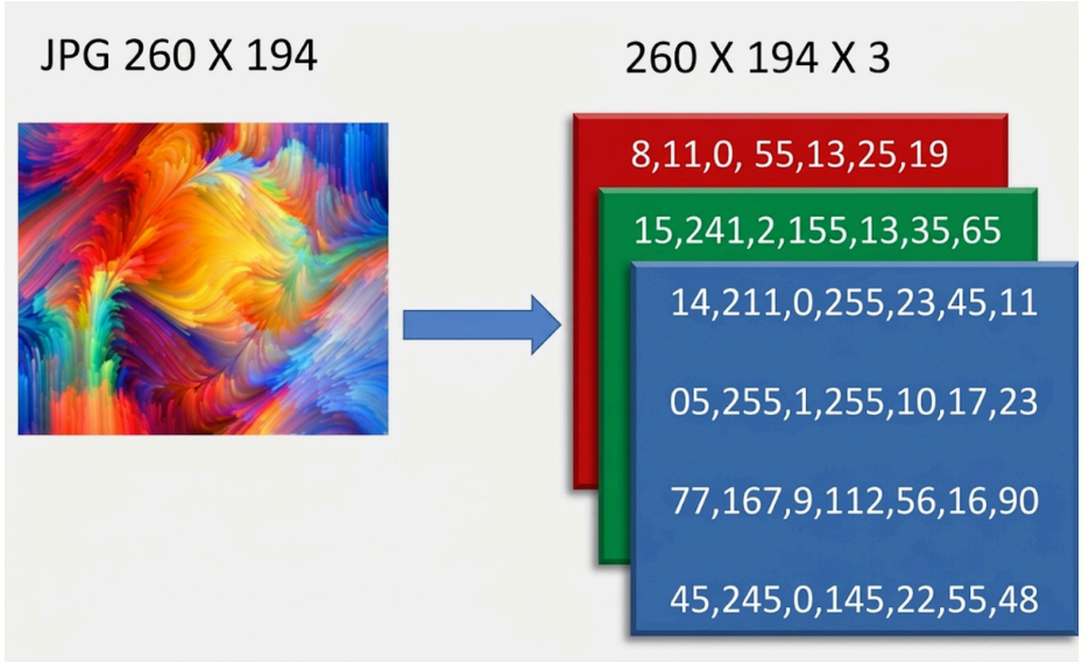

نشاط ٢ | دقيقة واحدة ⏳

كيف يمكن تصنيف هذه الزهور؟

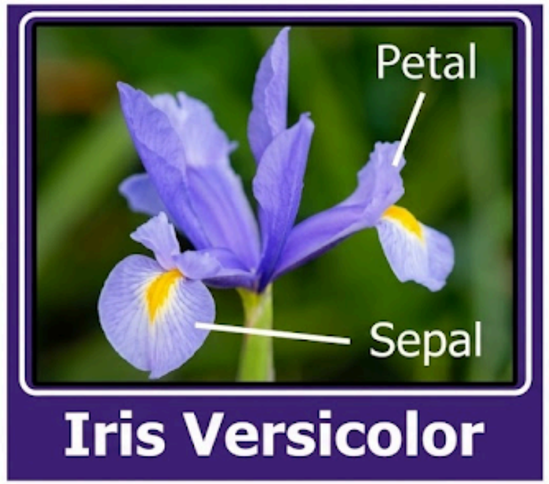

أنواع البيانات

- البيانات الجدولية التقليدية

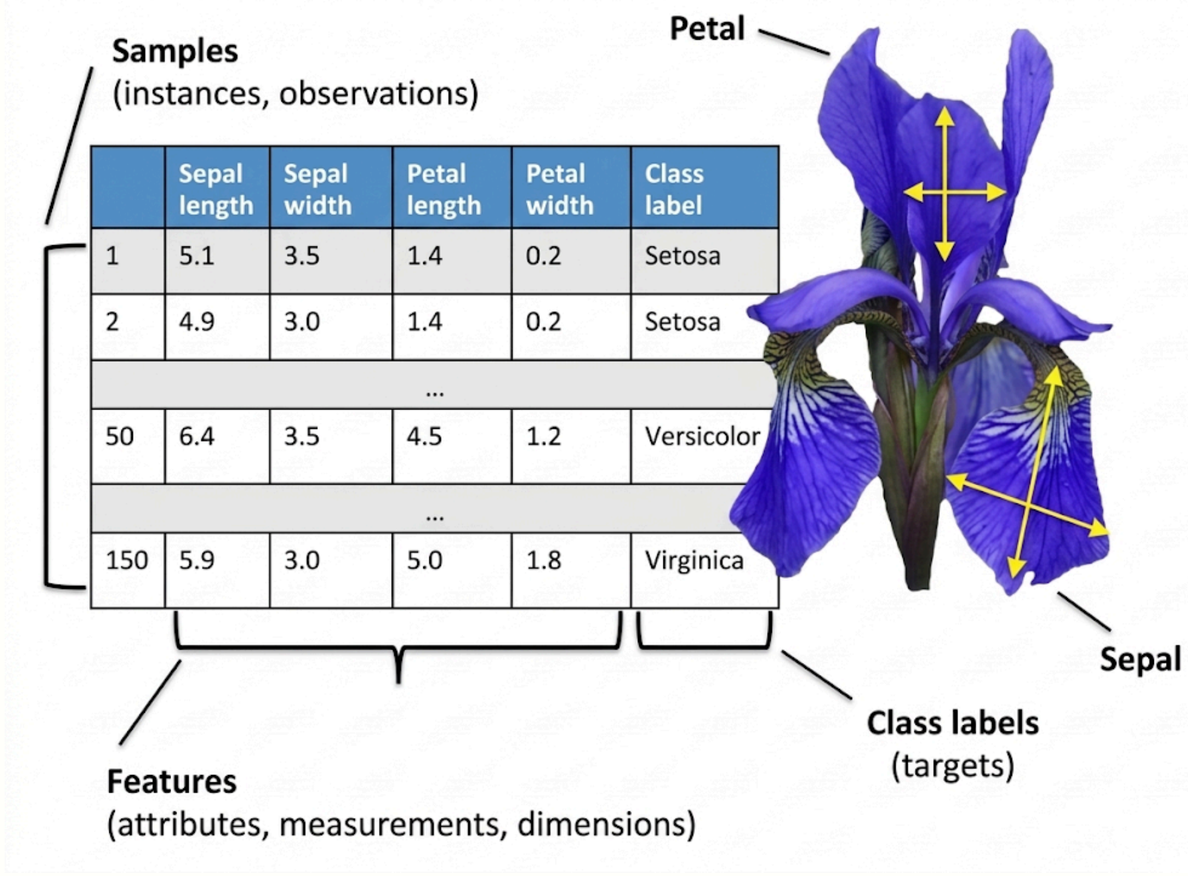

	Sepal length	Sepal width	Petal length	Petal width	Class label
1	5.1	3.5	1.4	0.2	Setosa
2	4.9	3.0	1.4	0.2	Setosa
...					
50	6.4	3.5	4.5	1.2	Versicolor
...					
150	5.9	3.0	5.0	1.8	Virginica

أنواع البيانات

- البيانات الجدولية التقليدية

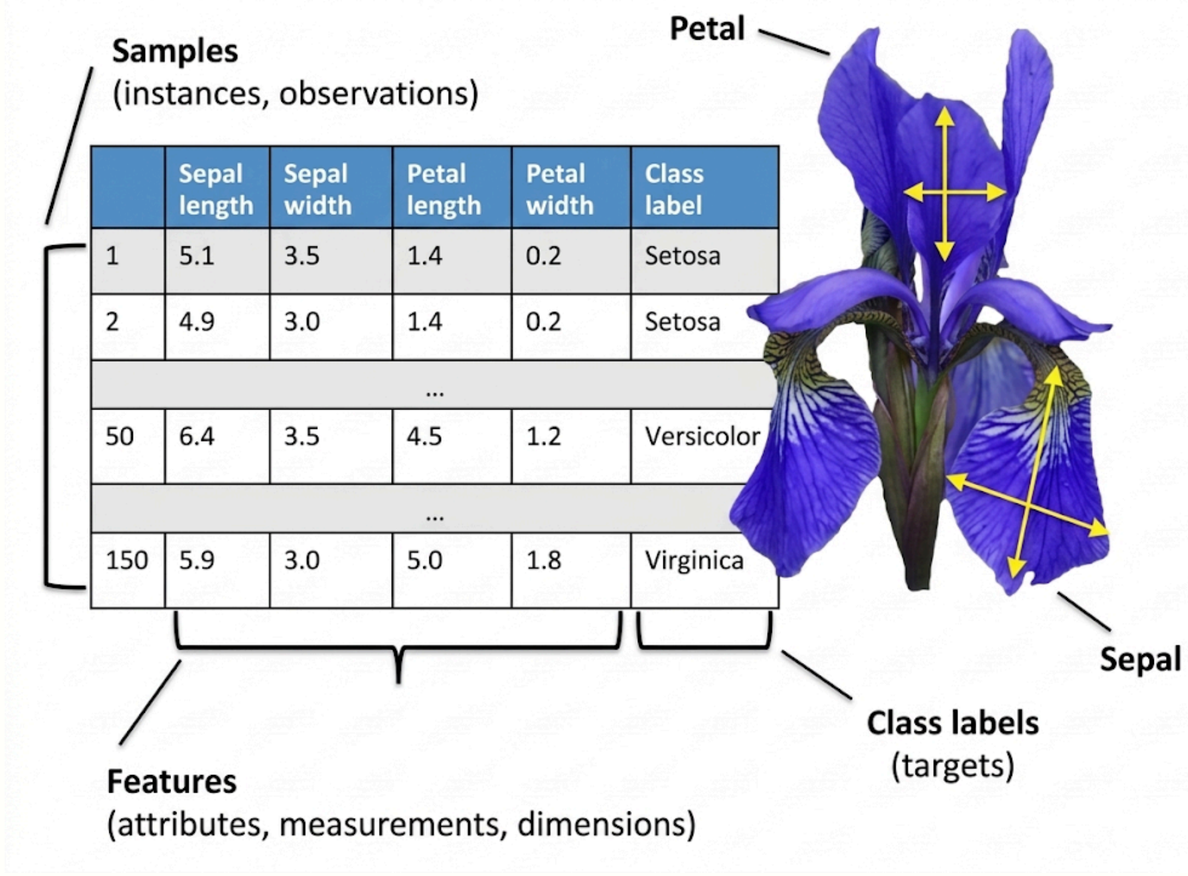

	Sepal length	Sepal width	Petal length	Petal width	Class label
1	5.1	3.5	1.4	0.2	Setosa
2	4.9	3.0	1.4	0.2	Setosa
...					
50	6.4	3.5	4.5	1.2	Versicolor
...					
150	5.9	3.0	5.0	1.8	Virginica

ما المشكلة؟

أنواع البيانات

- البيانات الجدولية التقليدية

- الميزات التي يصممها الإنسان تلتقط فقط الأنماط البسيطة والخطية.

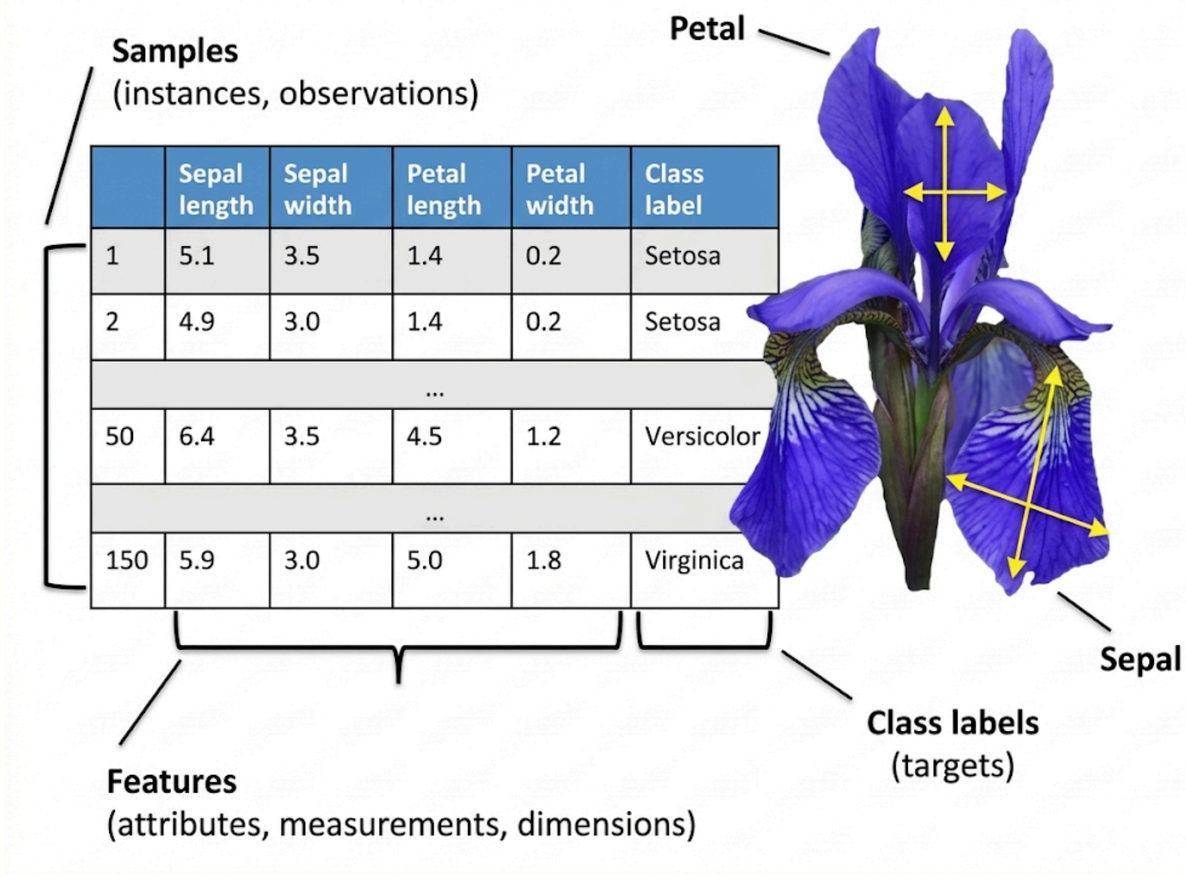

	Sepal length	Sepal width	Petal length	Petal width	Class label
1	5.1	3.5	1.4	0.2	Setosa
2	4.9	3.0	1.4	0.2	Setosa
...					
50	6.4	3.5	4.5	1.2	Versicolor
...					
150	5.9	3.0	5.0	1.8	Virginica

أنواع البيانات

- في تعلّم الآلة، يتم أولًا تحويل الصور إلى ميزات مصمّمة يدويًا.

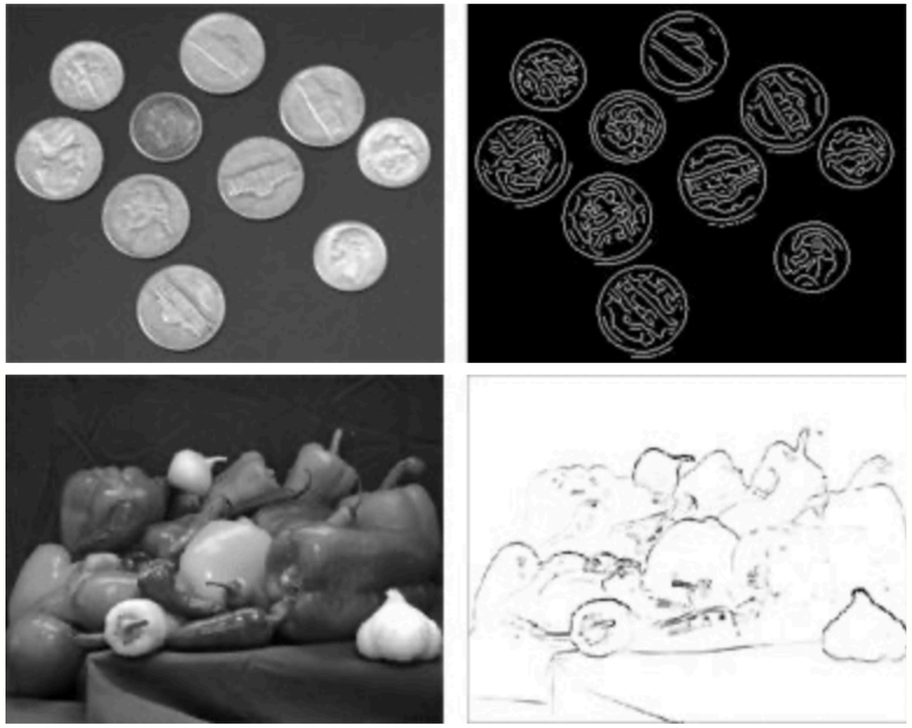

الحواف (Edges)

أنواع البيانات

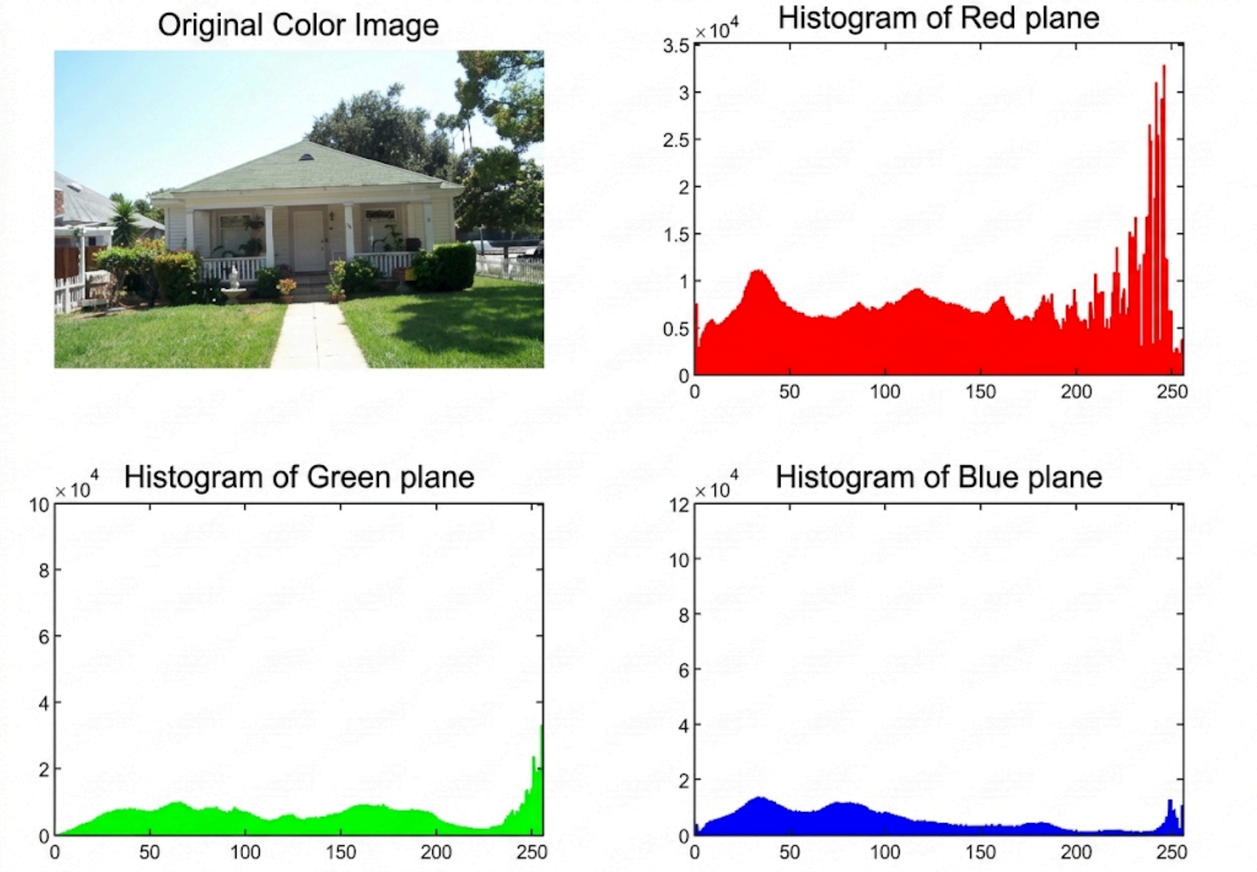

مدرجات الألوان (Color Histograms)

أنواع البيانات

512 × 512 pixels

Feature extraction

1,5
0,8
0,1
2,6
...

Feature vector

ما المشكلة هنا ؟

أنواع البيانات

512 × 512 pixels

Feature extraction

1,5
0,8
0,1
2,6
...

Feature vector

تُفقد الكثير من المعلومات الموجودة في البيانات الخام عند اختزالها إلى عدد قليل من الميزات.

أنواع البيانات

تحتاج خوارزميات تعلّم الآلة التقليدية إلى ميزات يتم استخراجها يدويًا، بينما يتعلّم التعلّم العميق الميزات مباشرةً من الصور بشكل تلقائي.

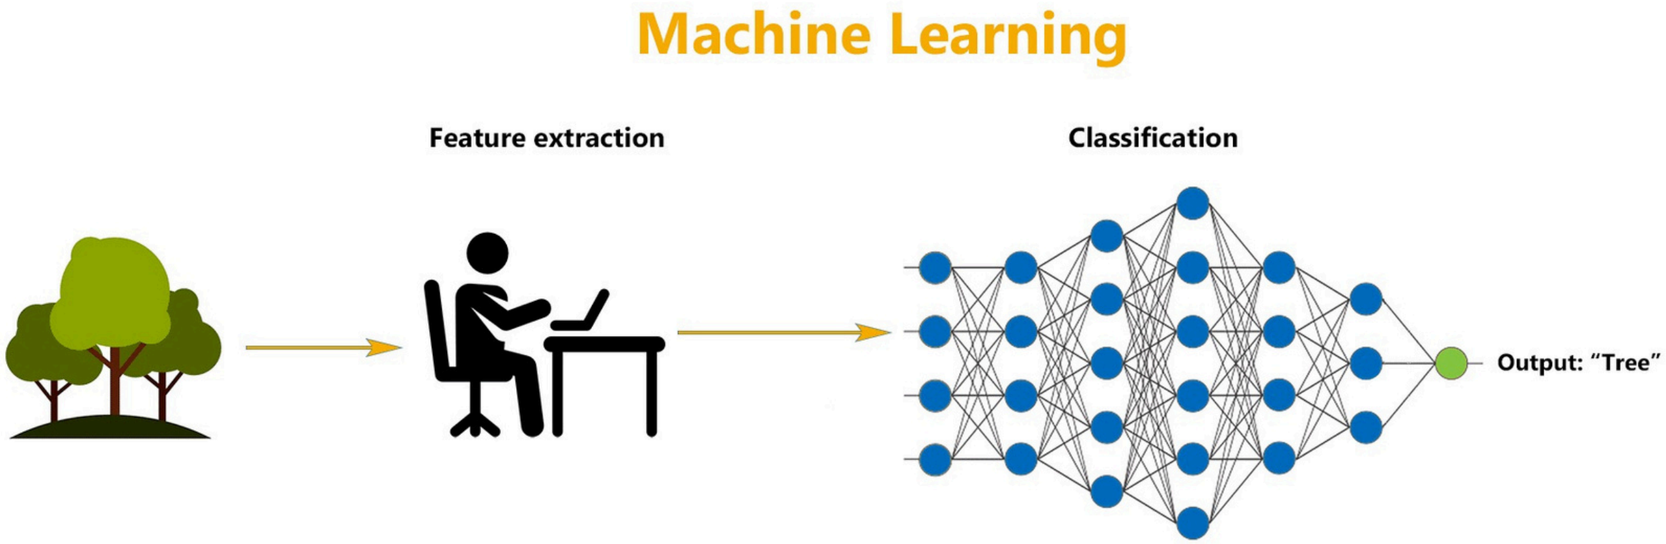

أنواع البيانات

تحتاج خوارزميات تعلّم الآلة التقليدية إلى ميزات يتم استخراجها يدويًا، بينما يتعلّم التعلّم العميق الميزات مباشرةً من الصور بشكل تلقائي.

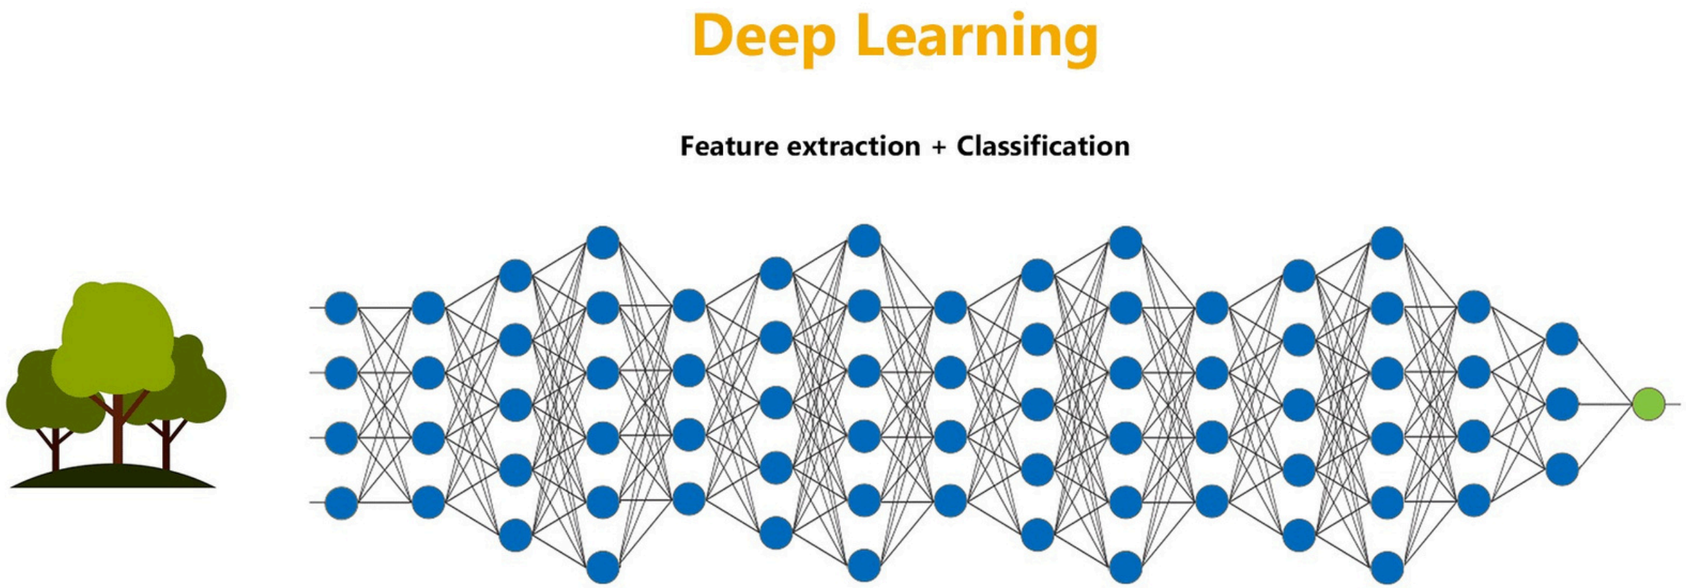

أنواع البيانات

البيانات النصية (Textual Data)

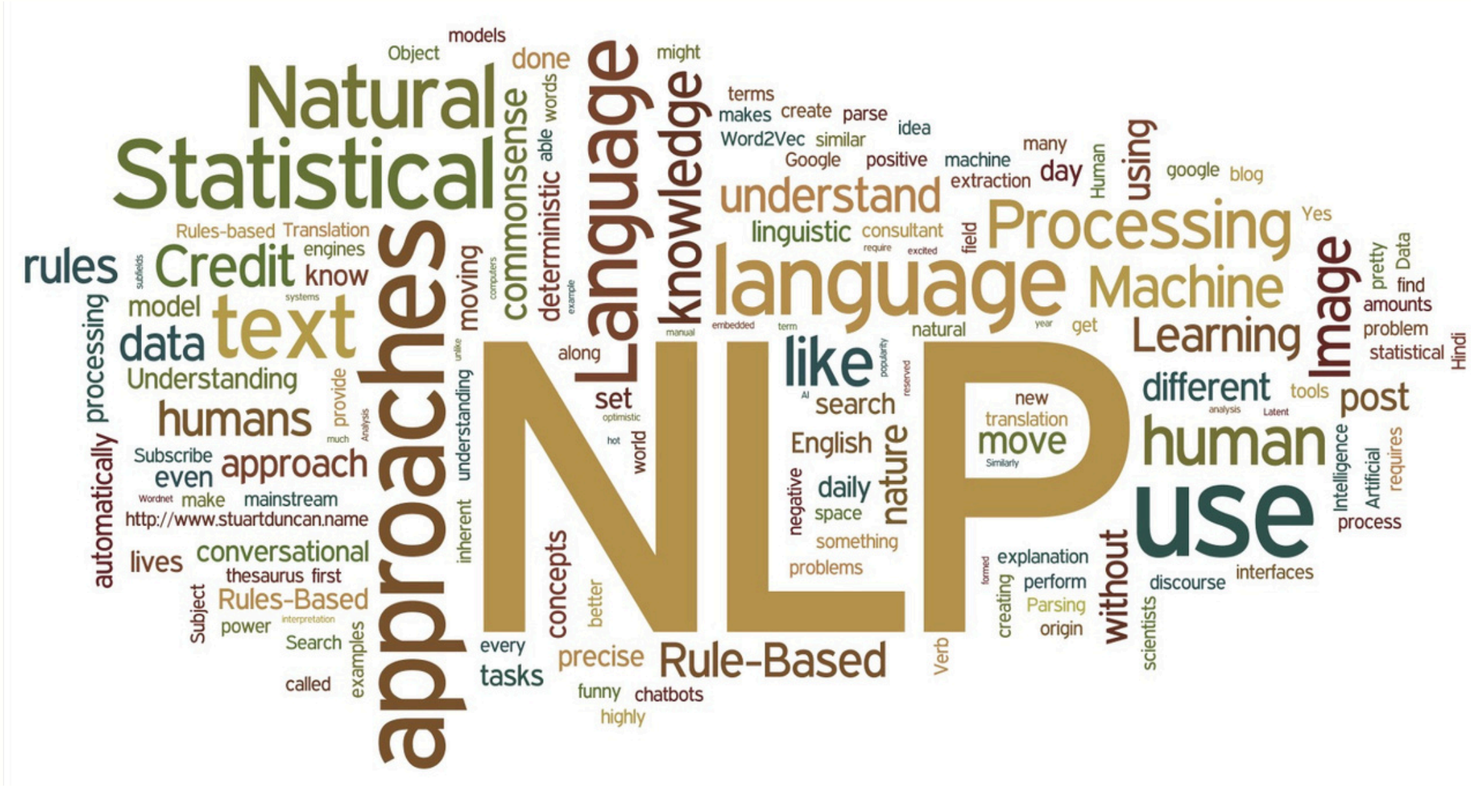

أنواع البيانات

البيانات النصية (Textual Data)

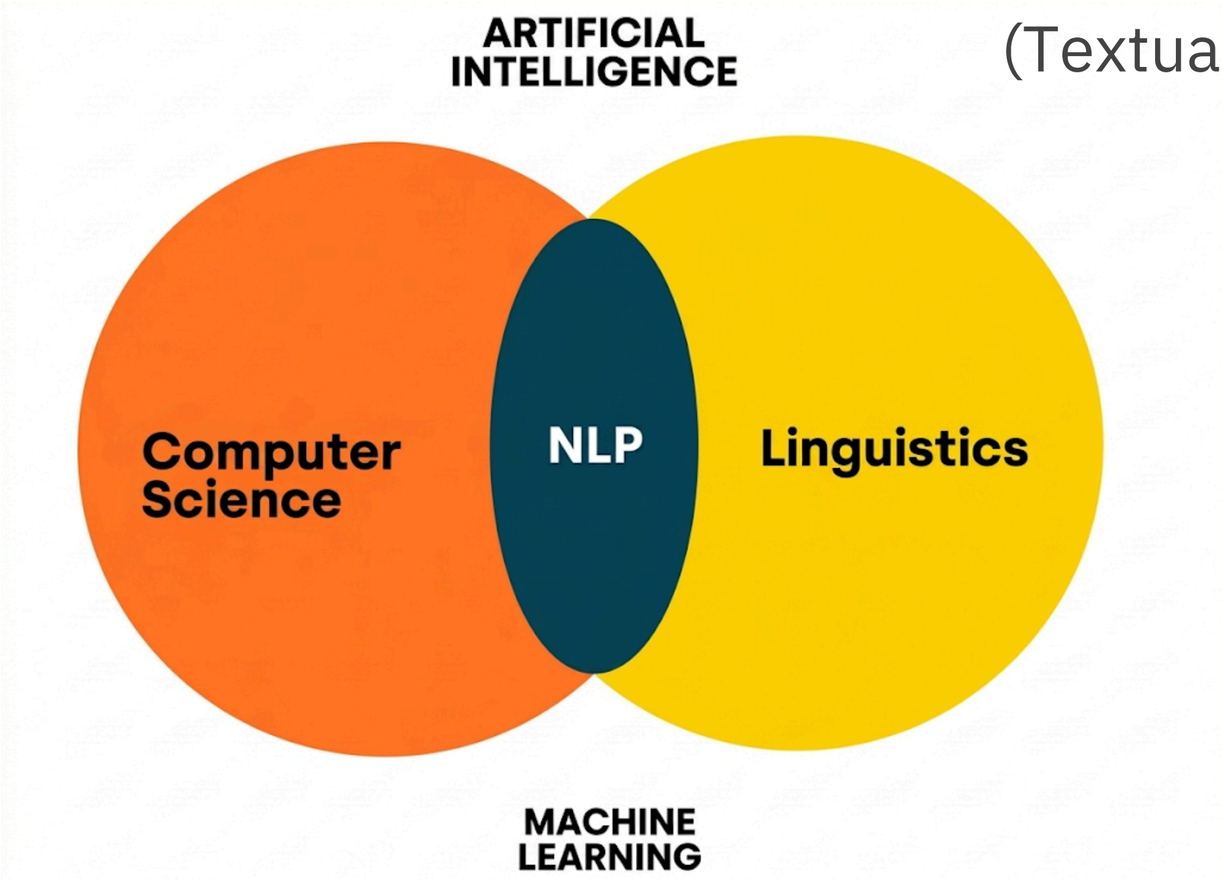

البيانات النصية (Textual Data)

تسلسلية: الكلمات لها ترتيب وبنية.

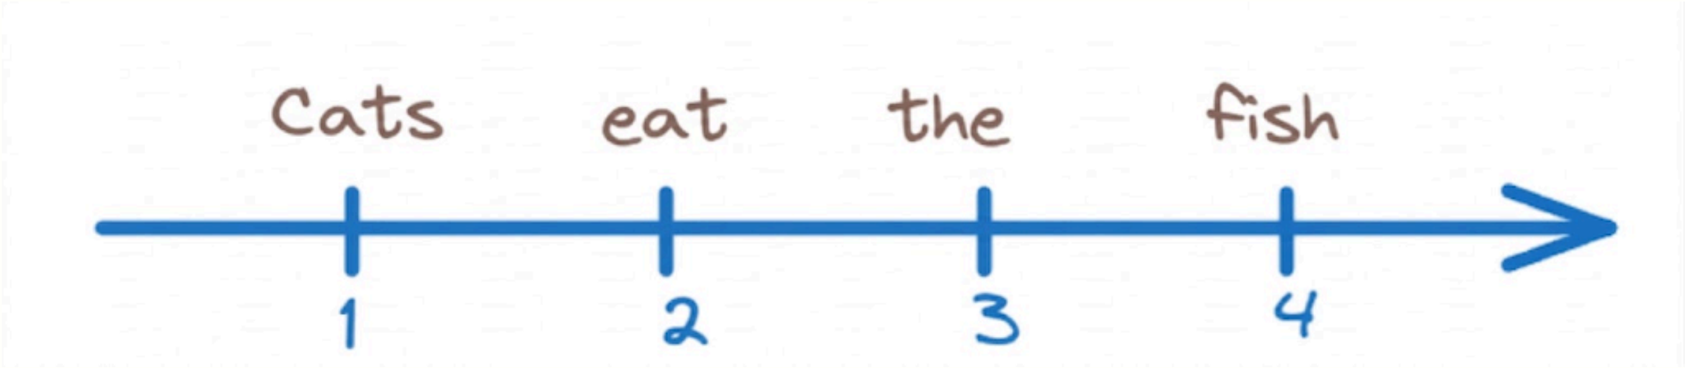

البيانات النصية (Textual Data)

عالية الأبعاد: يمكن أن يصل حجم المفردات إلى آلاف أو ملايين الكلمات.

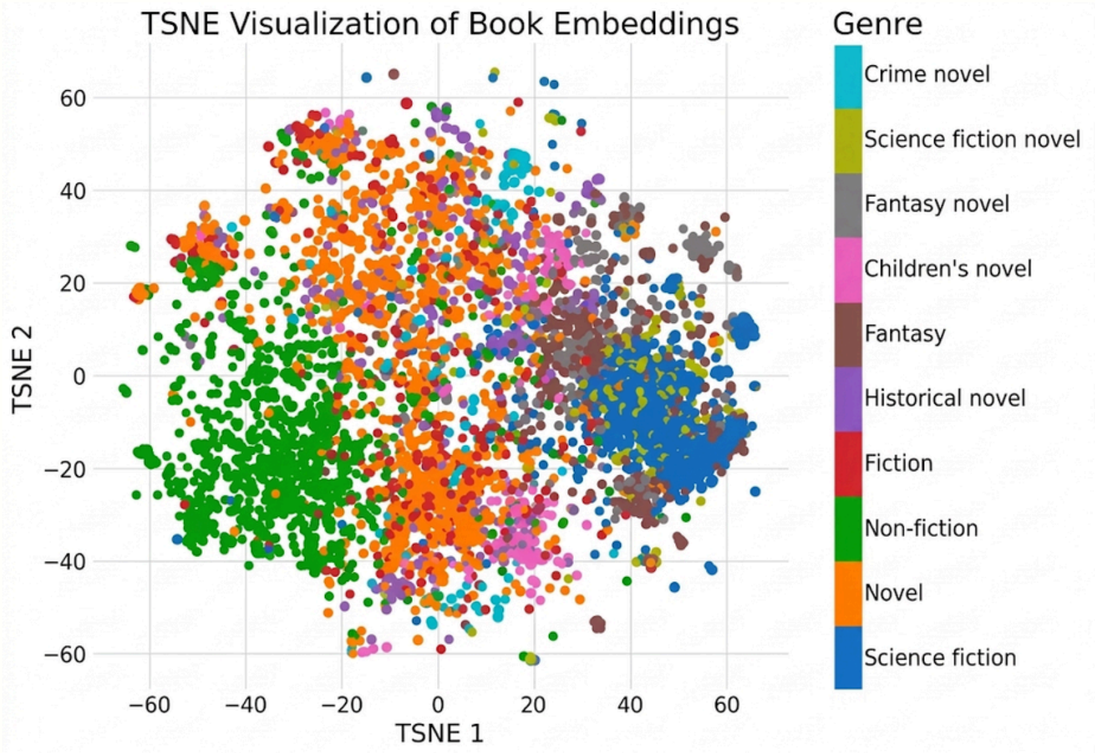

البيانات النصية (Textual Data)

غامضة: قد تحمل الكلمة نفسها معاني مختلفة في جمل مختلفة.

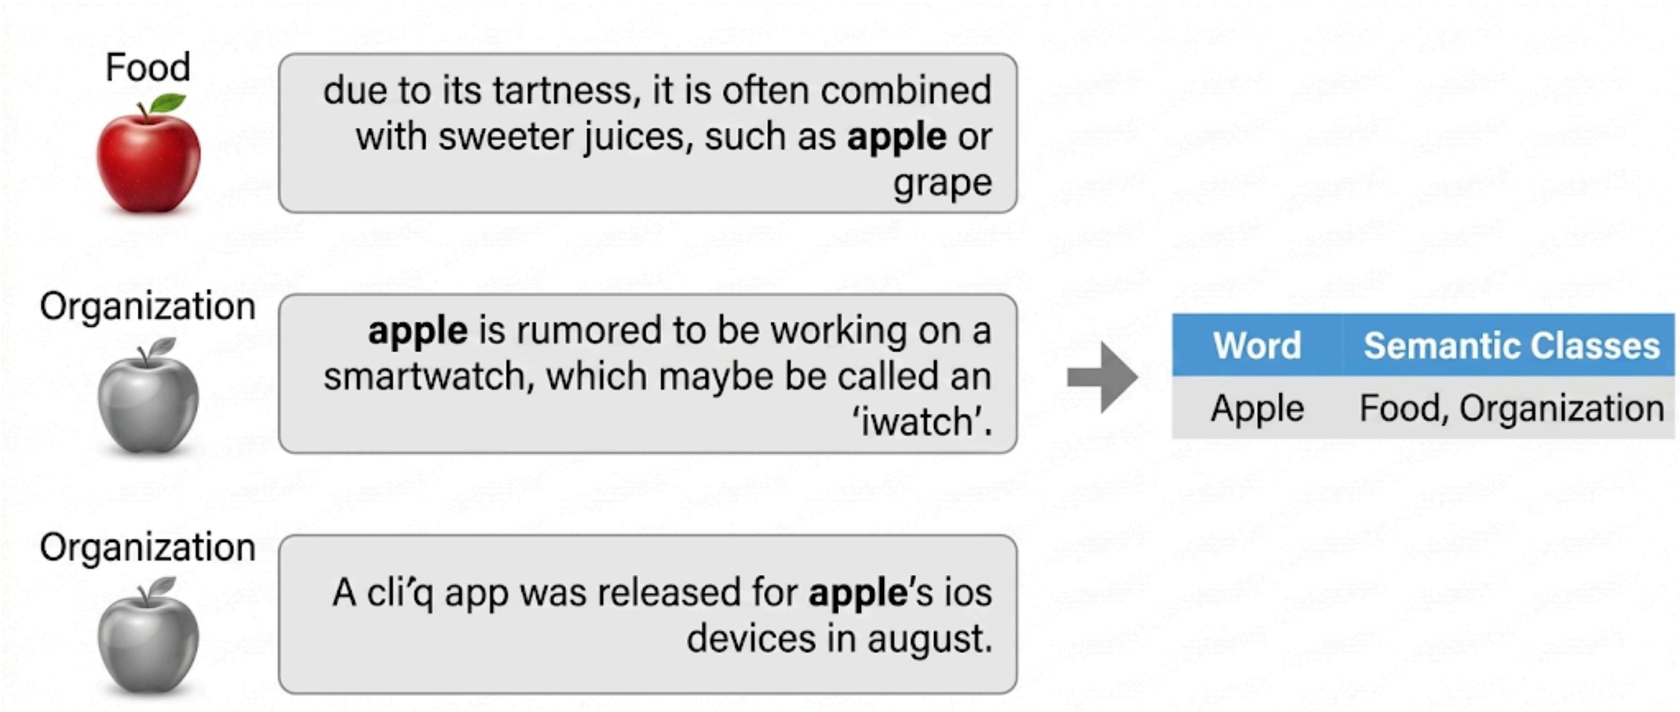

البيانات النصية (Textual Data)

تمثيل النصوص

I love this movie! It's sweet, but with satirical humor. The dialogue is great and the adventure scenes are fun... It manages to be whimsical and romantic while laughing at the conventions of the fairy tale genre. I would recommend it to just about anyone. I've seen it several times, and I'm always happy to see it again whenever I have a friend who hasn't seen it yet!

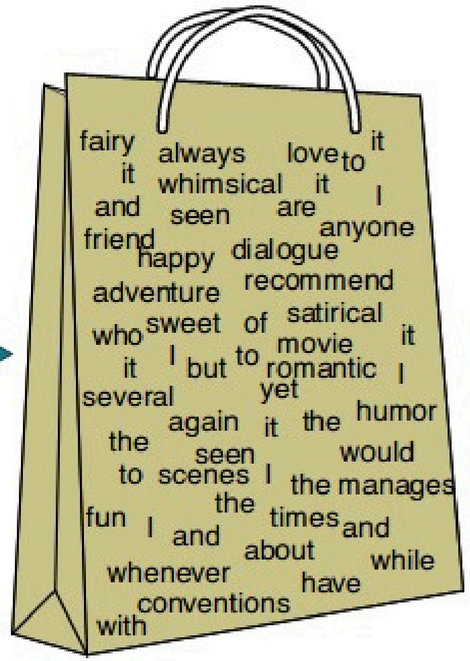

it	6
I	5
the	4
to	3
and	3
seen	2
yet	1
would	1
whimsical	1
times	1
sweet	1
satirical	1
adventure	1
genre	1
fairy	1
humor	1
have	1
great	1
...	...

حقيبة الكلمات (Bag of Words)

البيانات النصية (Textual Data)

تمثيل النصوص

حقيبة الكلمات (Bag of Words)

Document	NLP	is	fun	very	powerful
Doc1: NLP is fun	?	?	?	?	?
Doc2: NLP is very fun	?	?	?	?	?
Doc3: NLP is powerful	?	?	?	?	?

أنواع البيانات

تمثيل النصوص

حقيبة الكلمات (Bag of Words)

Document	NLP	is	fun	very	powerful
Doc1: NLP is fun	1	1	1	0	0
Doc2: NLP is very fun	1	1	1	1	0
Doc3: NLP is powerful	1	1	0	0	1

البيانات النصية (Textual Data)

تكرار المصطلح - عكس تكرار الوثائق (Term Frequency-Inverse Document Frequency)

TF-IDF

- تكرار المصطلح (TF)
- يقيس عدد مرات ظهور الكلمة في المستند.

$$TF_{ij} = \frac{\text{Number of times the term appears in the document}}{\text{Total number of terms in the document}}$$

البيانات النصية (Textual Data)

تكرار المصطلح - عكس تكرار الوثائق (Term Frequency-Inverse Document Frequency)

TF-IDF

- عكس تكرار الوثائق (IDF)
- يقيس مدى ندرة أو شيوع الكلمة بين جميع المستندات في مجموعة البيانات.

$$IDF_i = \log\left(\frac{\text{Total number of documents}}{\text{Number of documents containing term } i}\right)$$

البيانات النصية (Textual Data)

تكرار المصطلح - عكس تكرار الوثائق (Term Frequency-Inverse Document Frequency)

TF-IDF

$$TF_{ij} = \frac{\text{Number of times the term appears in the document}}{\text{Total number of terms in the document}}$$

$$IDF_i = \log\left(\frac{\text{Total number of documents}}{\text{Number of documents containing term } i}\right)$$

- IDF مرتفع ⇒ الكلمة نادرة ولكنها ذات قيمة.
- IDF منخفض ⇒ الكلمة شائعة (مثل: «ال»، «و»، «من»).

أكاديمية علو

البيانات النصية (Textual Data)

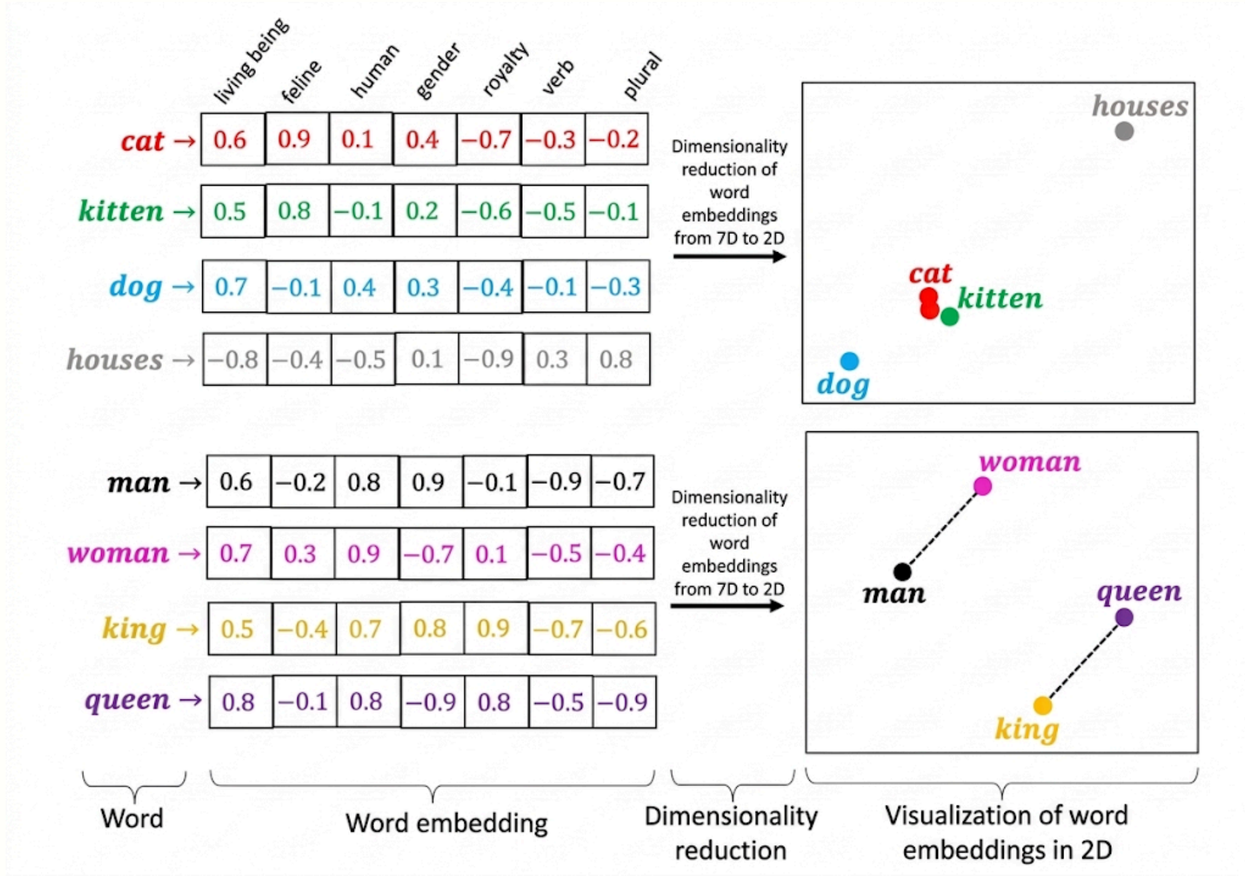

تمثيل الكلمات (Word Embedding)

البيانات النصية (Textual Data)

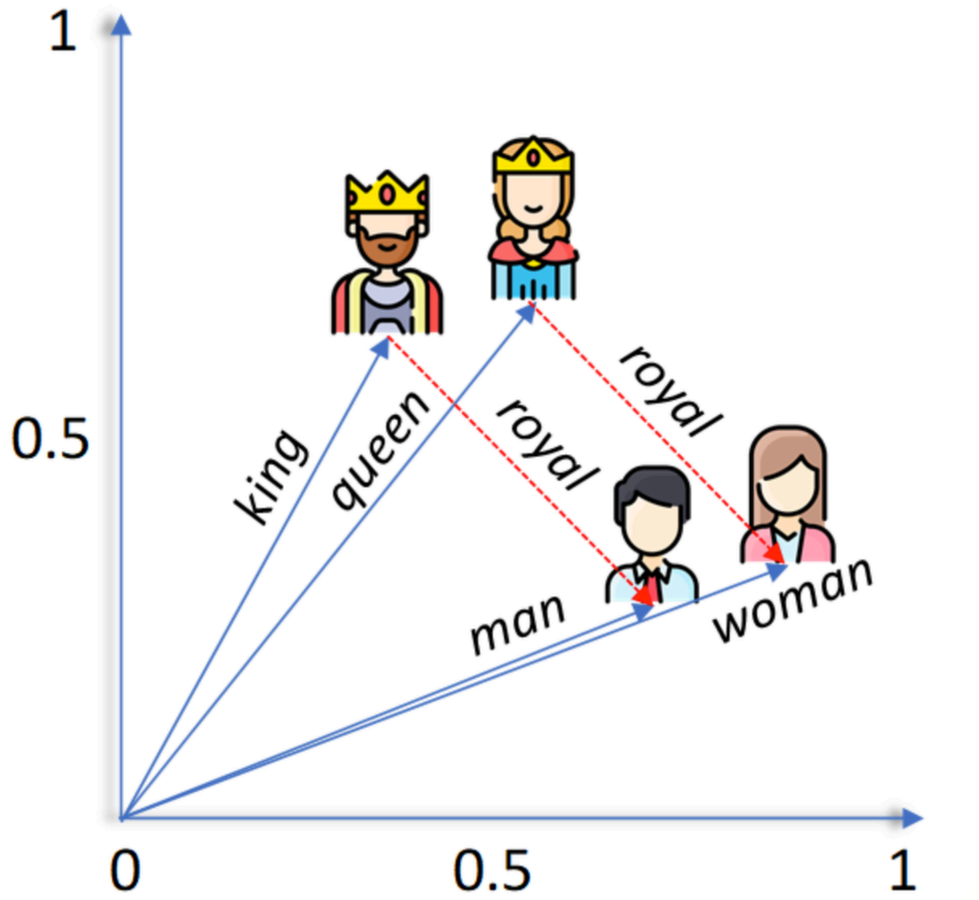

تمثيل الكلمات (Word Embedding)

أنواع البيانات

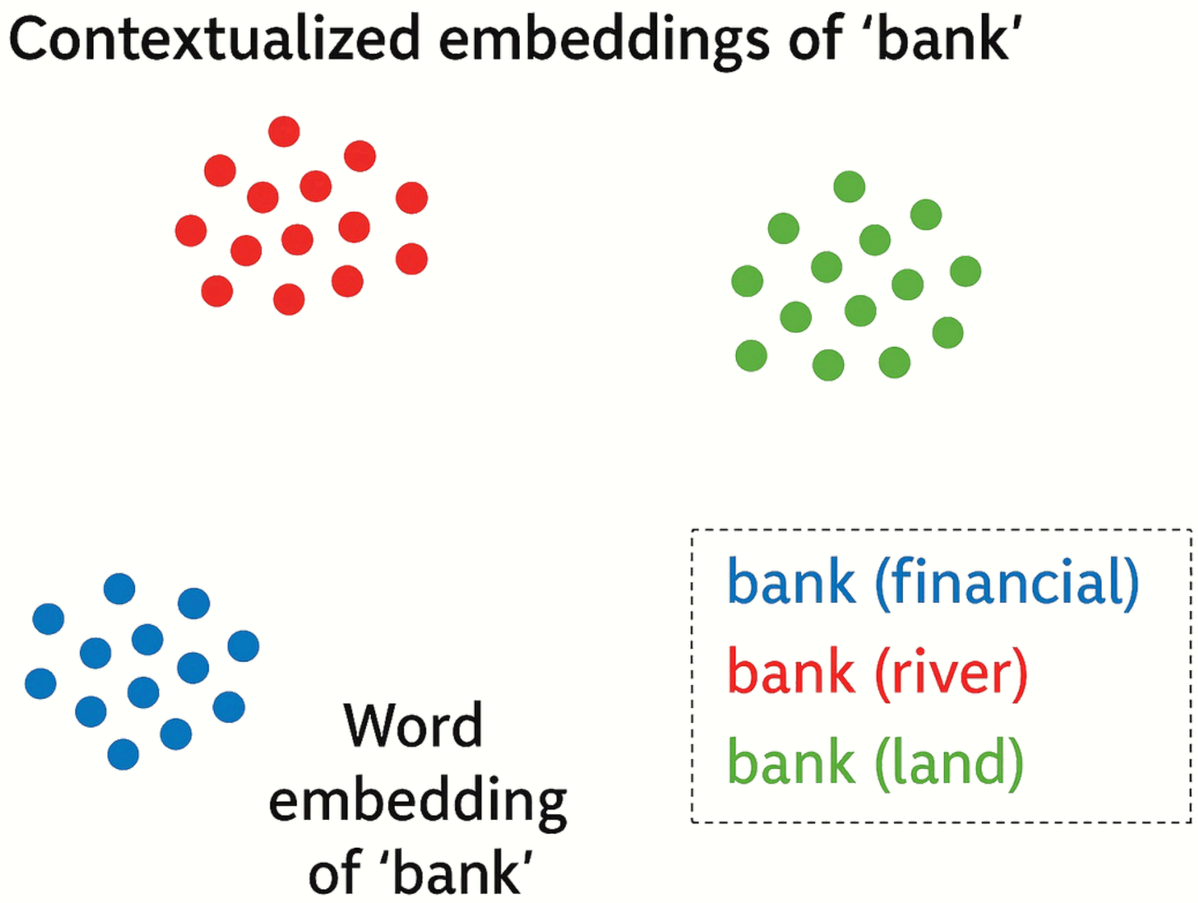

التضمينات السياقية (Contextualized Embeddings)

أنواع البيانات

البيانات الصوتية (Audio Data)

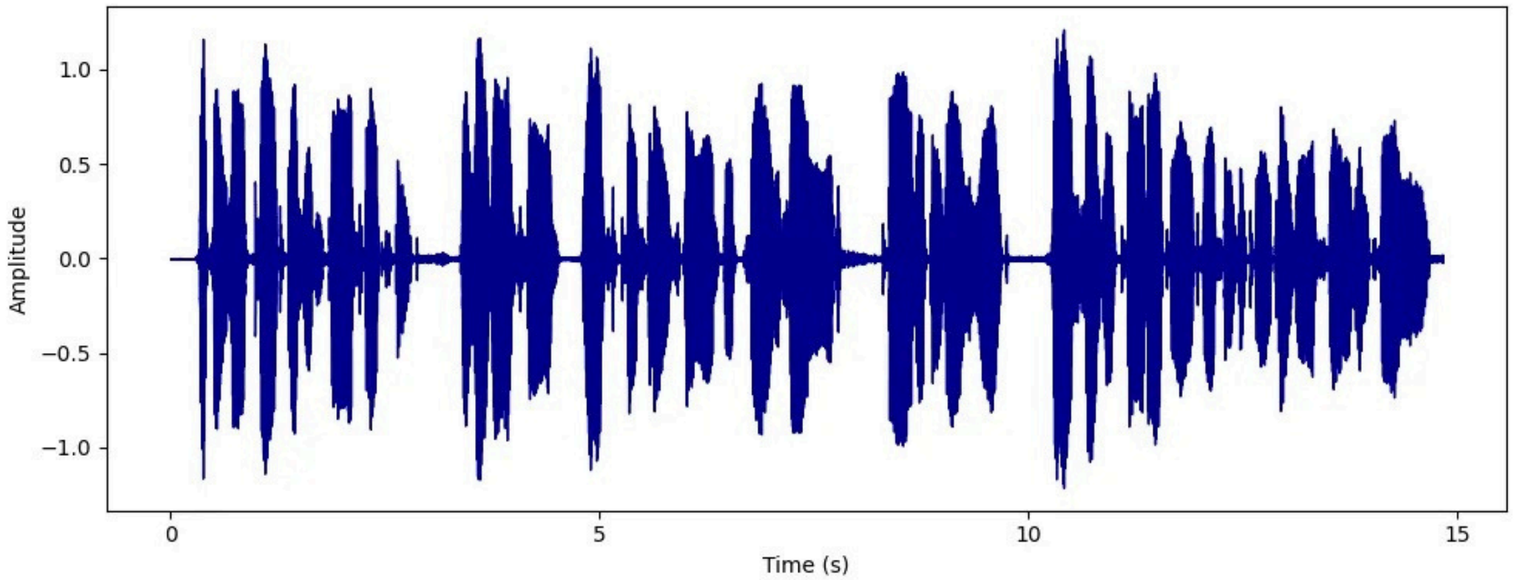

أنواع البيانات

البيانات الصوتية (Audio Data)

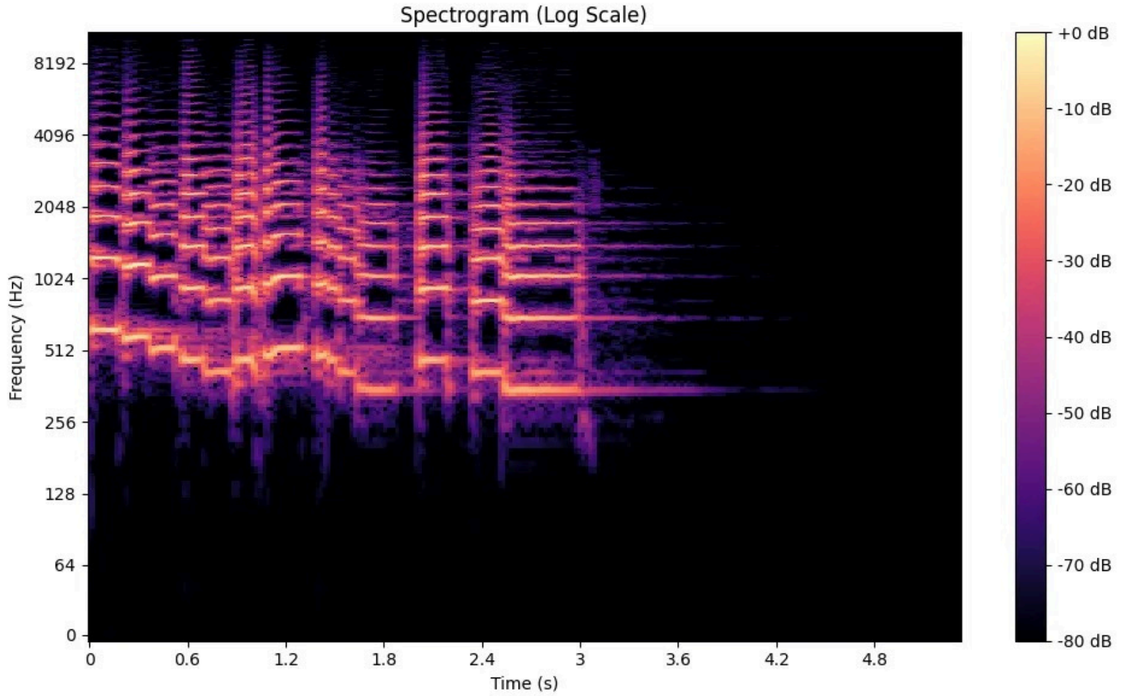

مصادر البيانات (Sources of Data)

kaggle

OPEN DATA PLATFORM
منصـــة البيـــانات المفتـــوحة

OpenML

استراحة

10 دقائق

أهلًا بعودتكم

تحليل البيانات الاستكشافي EDA

ما هو التحليل الاستكشافي للبيانات (EDA)؟

يُستخدم التحليل الاستكشافي للبيانات (EDA) لتحليل مجموعات البيانات ودراستها وتلخيص أهم خصائصها، وغالبًا ما يعتمد على أساليب تصوير البيانات.

طوّر عالم الرياضيات الأمريكي جون توكي (John Tukey) تقنيات EDA في سبعينيات القرن الماضي، ولا تزال هذه التقنيات تُستخدم على نطاق واسع اليوم في عملية استكشاف البيانات.

لماذا نحتاج إلى EDA؟

قبل أن نضع افتراضات أو نبني نموذجًا، نحتاج إلى فهم البيانات.

يساعدنا على:

- اكتشاف الأنماط والعلاقات.
- اكتشاف القيم الشاذة والمشكلات في البيانات.
- فهم خصائص المتغيرات.
- اختيار الطرق المناسبة لتحليل البيانات.

وغالبًا ما نستخدم الرسوم البيانية لتسهيل فهم البيانات.

ماذا نستكشف في البيانات؟

أثناء تحليل البيانات، نبحث عن:

الأنماط ← هل توجد أنماط متكررة؟

القيم الشاذة ← هل توجد قيم غير طبيعية؟

العلاقات ← هل توجد علاقة بين المتغيرات؟

الأخطاء ← هل توجد بيانات ناقصة أو غير صحيحة؟

أنواع التحليل الاستكشافي للبيانات

هناك أربعة أنواع رئيسية:

- متغير واحد - بدون رسوم Univariate Non-Graphical
- متغير واحد - باستخدام الرسوم Univariate Graphical
- متعدد المتغيرات - بدون رسوم Multivariate Non-Graphical
- متعدد المتغيرات - باستخدام الرسوم Multivariate Graphical

تحليل متغير واحد (Univariate Analysis)

نركز على متغير واحد فقط لفهم خصائصه وتوزيعه.
مثل أعمار الطلاب
يمكننا معرفة:

- المتوسط.
- الحد الأدنى والأقصى.
- التوزيع.
- القيم الشاذة.

ومن الرسوم المستخدمة:
Histogram — Box Plot

تحليل متعدد المتغيرات (Multivariate Analysis)

نركز على متغيرين أو أكثر لفهم العلاقات بينها.

مثل ساعات الدراسة ↔ درجة الاختبار

يمكننا استخدام:

- Scatter Plot
- Grouped Bar Chart
- Heat Map
- Bubble Chart

لمعرفة كيف ترتبط المتغيرات ببعضها.

أشهر الرسوم المستخدمة في EDA

📊 Histogram لفهم توزيع البيانات.

📦 Box Plot لاكتشاف القيم الشاذة وفهم توزيع البيانات.

🔵 Scatter Plot لفهم العلاقة بين متغيرين.

🔥 Heat Map لعرض العلاقات والقيم باستخدام الألوان.

📈 Line Chart متابعة تغير البيانات عبر الزمن.

أدوات التحليل الاستكشافي للبيانات

يمكن تنفيذ EDA باستخدام العديد من الأدوات، وأشهرها:

- Python 🐍
- Pandas
- Matplotlib
- Seaborn
- R للتحليل الإحصائي وتصوير البيانات.

تنظيف البيانات (Data Cleaning)

ما هو تنظيف البيانات (Data Cleaning)؟

تنظيف البيانات هو عملية إصلاح وتصحيح وتجهيز البيانات الخام لتصبح دقيقة ومتسقة وقابلة للاستخدام في التحليل أو تعلّم الآلة.

تنظيف البيانات (Data Cleaning)؟

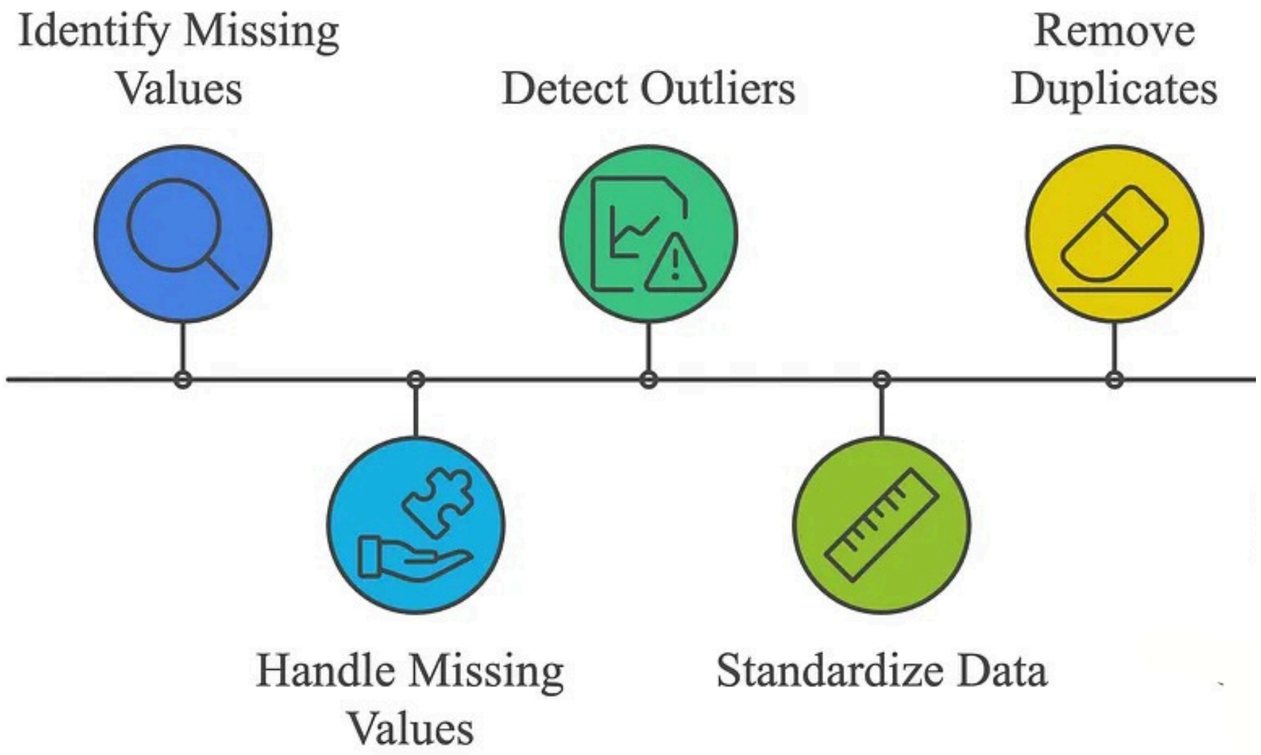

القيم المفقودة (Missing Values)

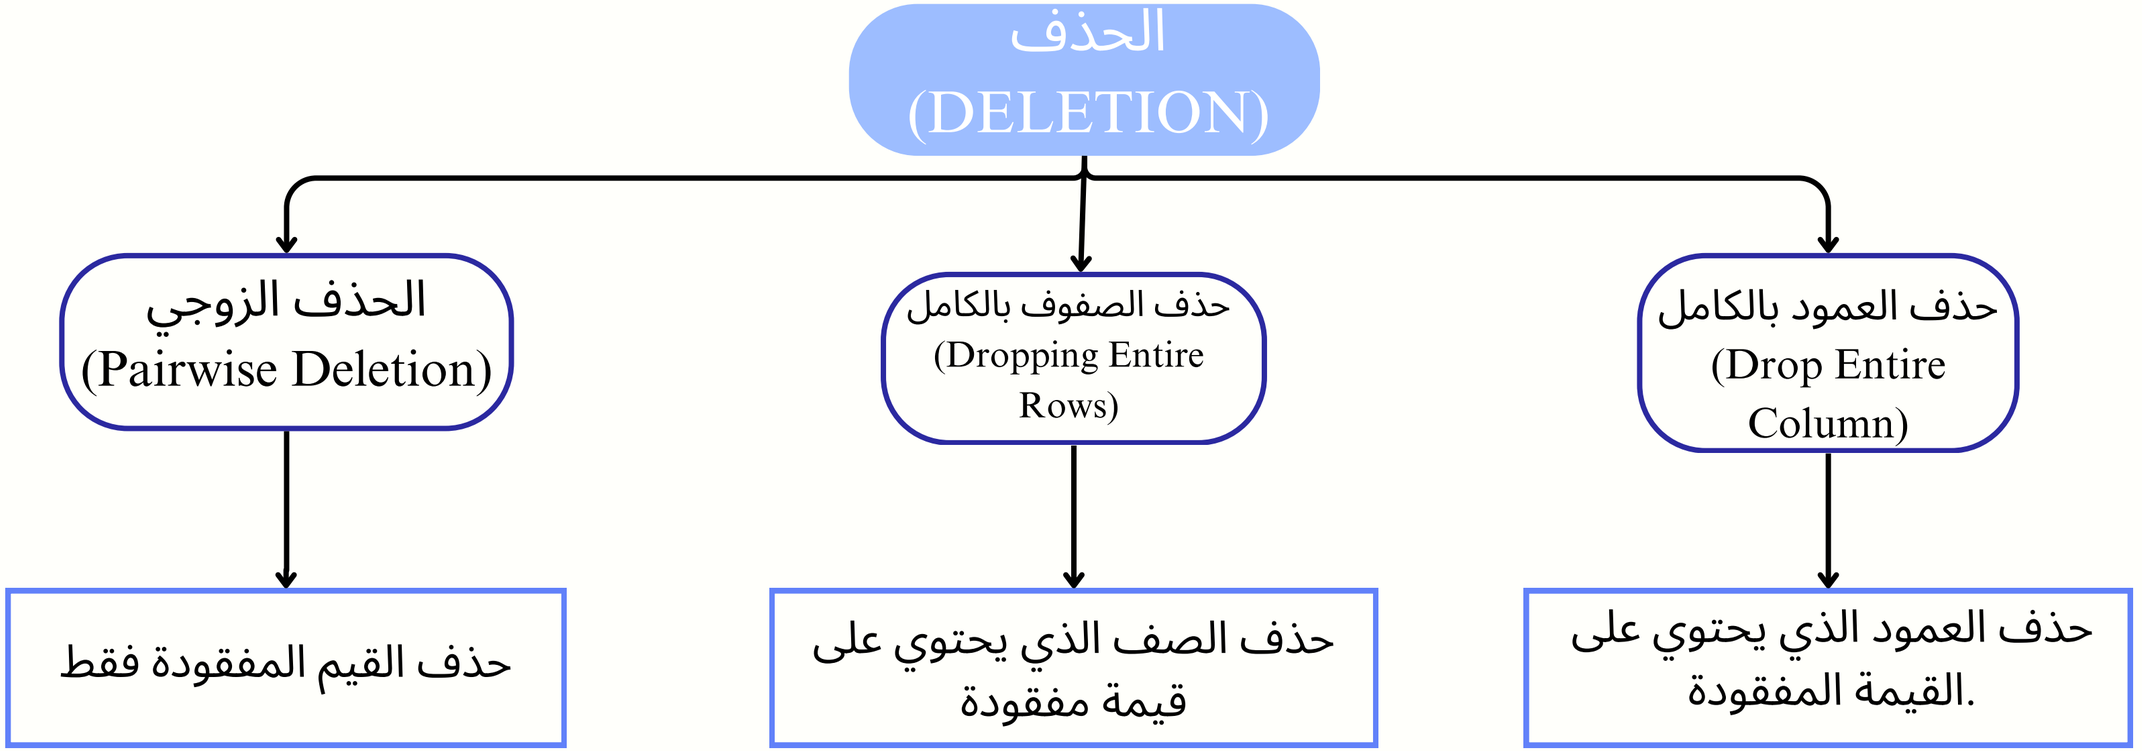

القيم المفقودة (Missing Values)

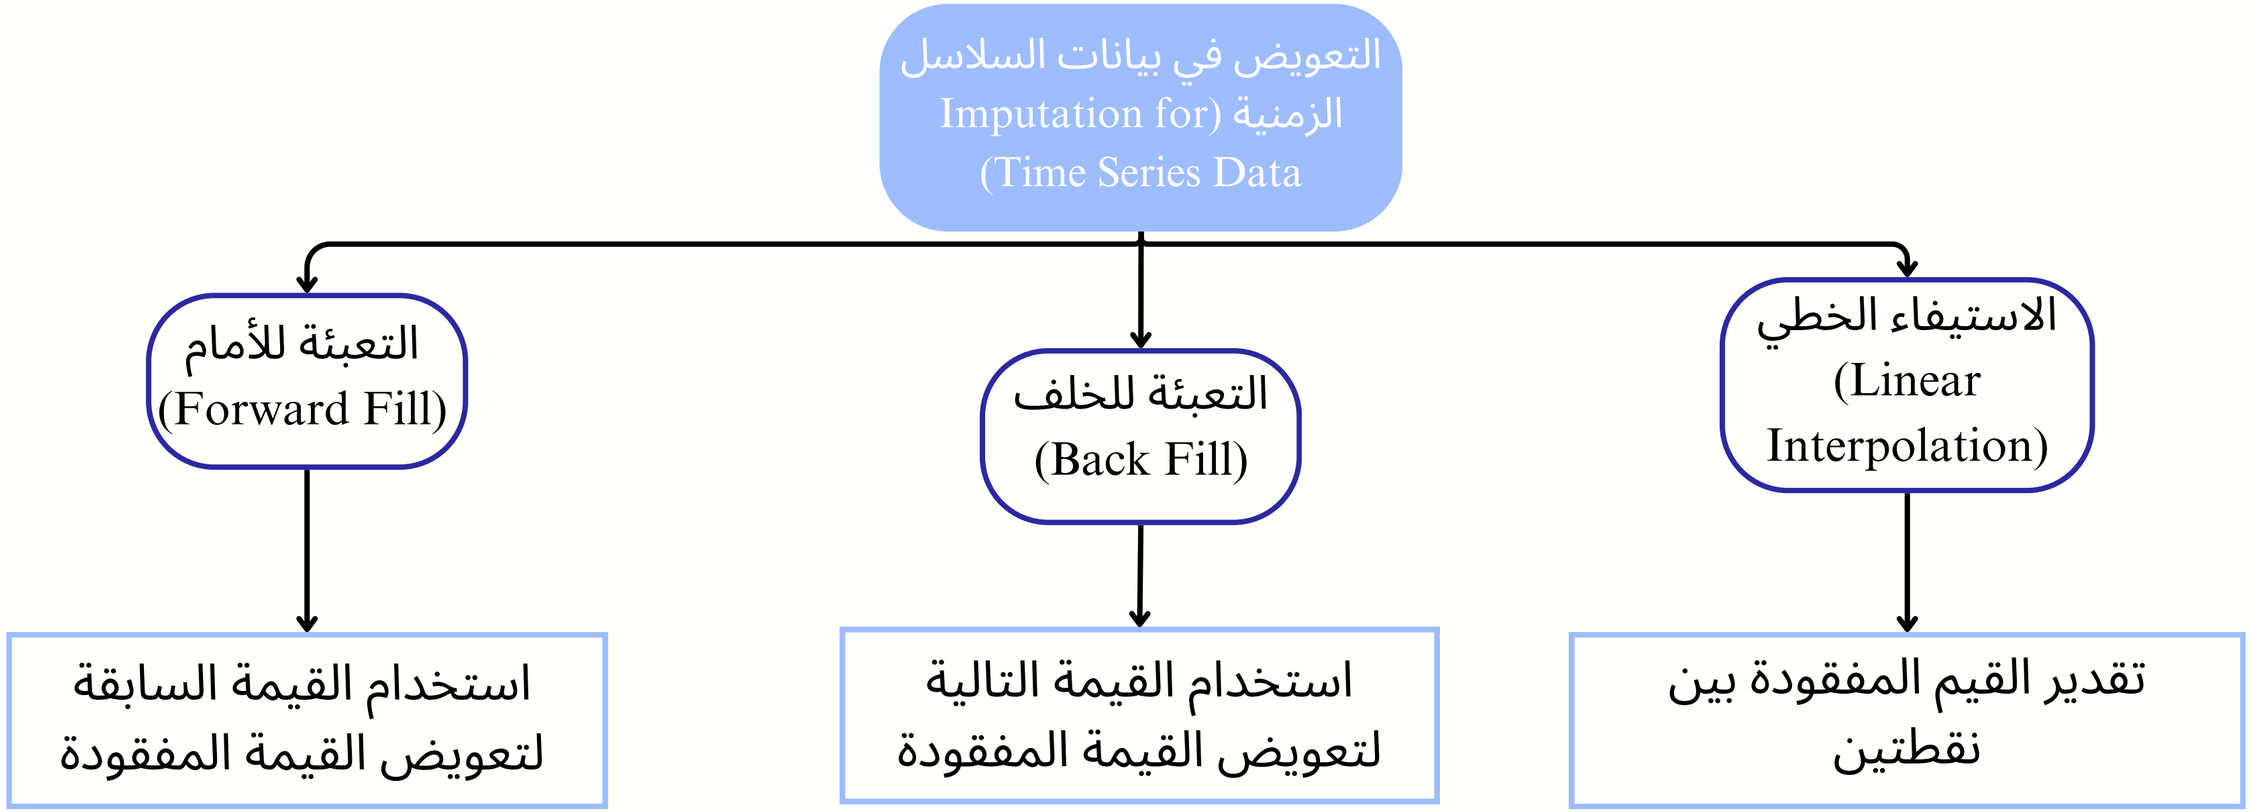

القيم المفقودة (Missing Values)

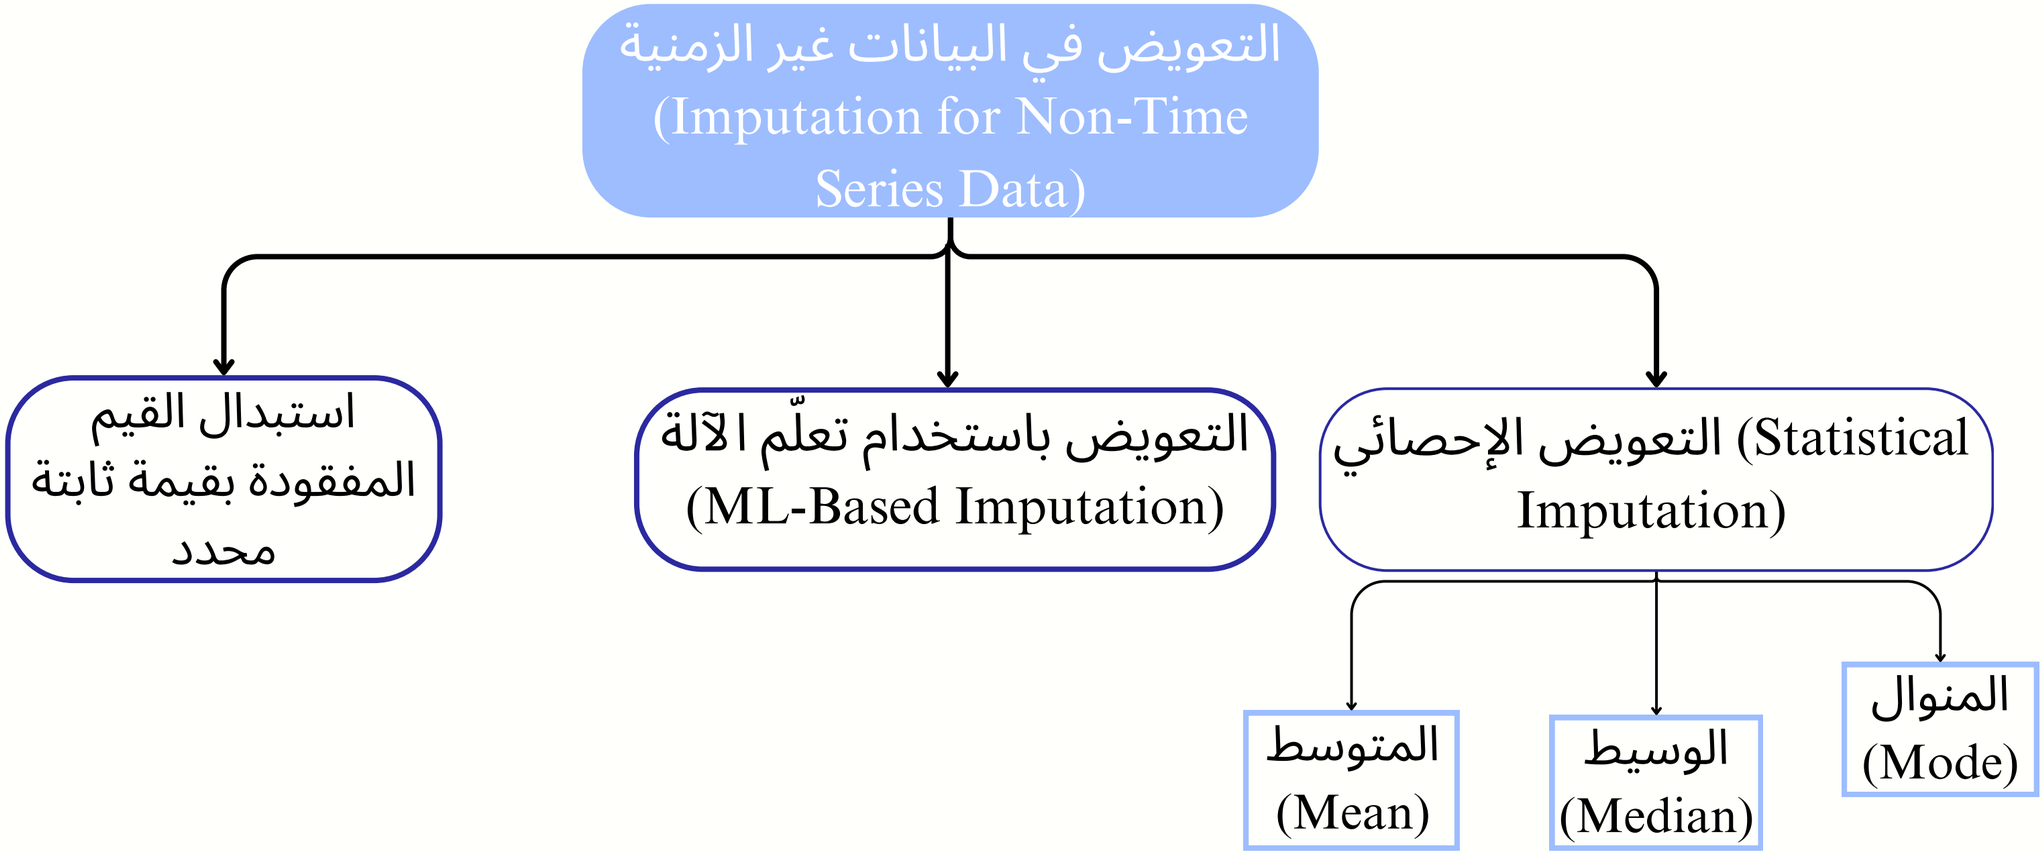

نشاط 3 | دقيقة واحدة ⏳

ما المشكلة في هذا المدرج التكراري؟

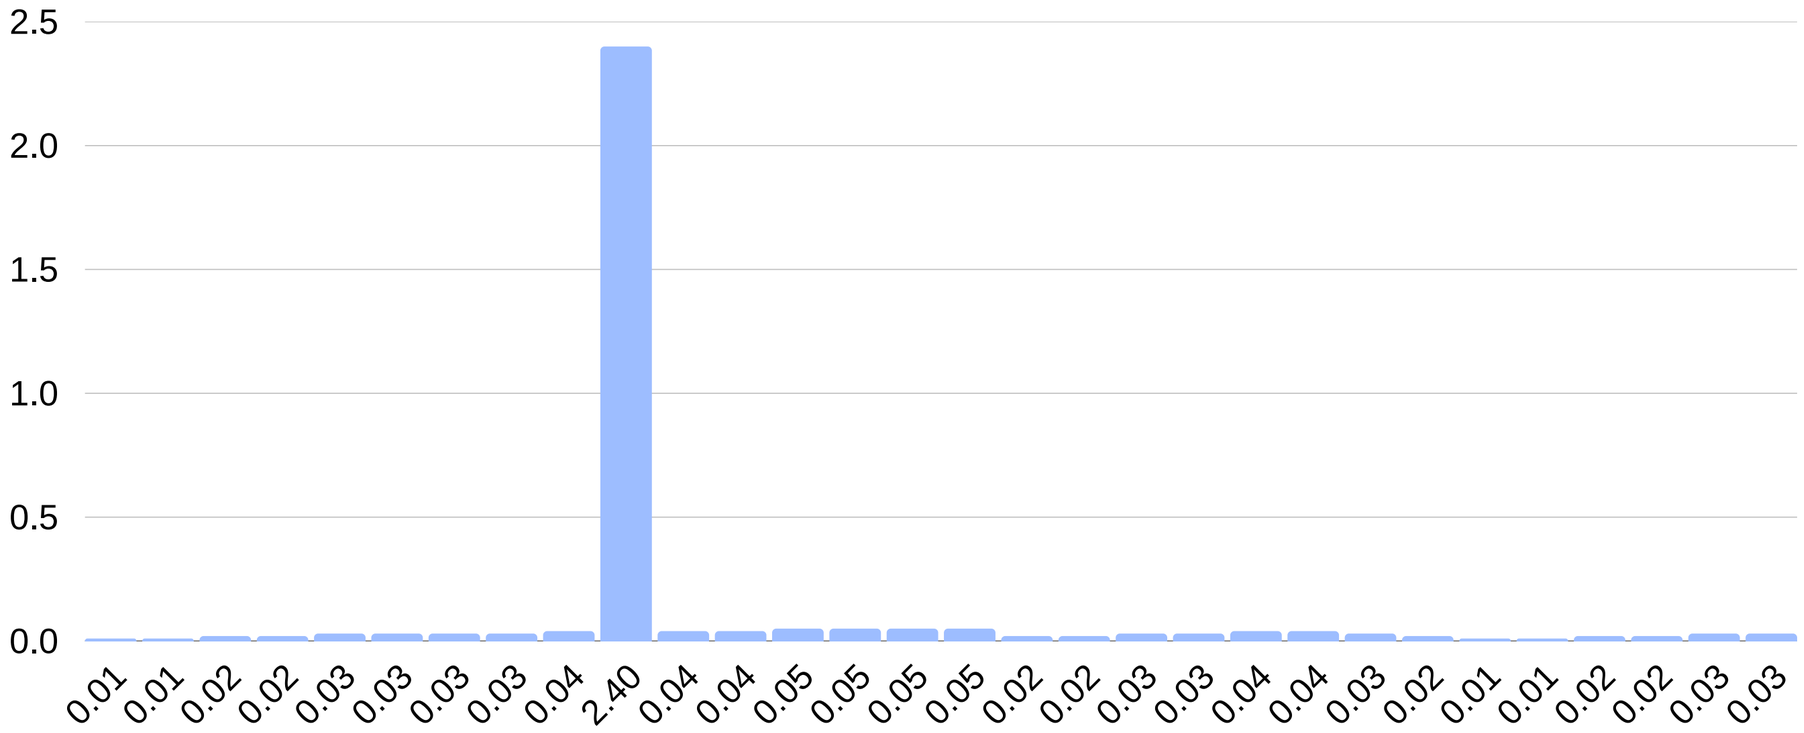

نشاط 3 | ⏳ دقيقة واحدة

ما المشكلة في هذا المدرج التكراري؟

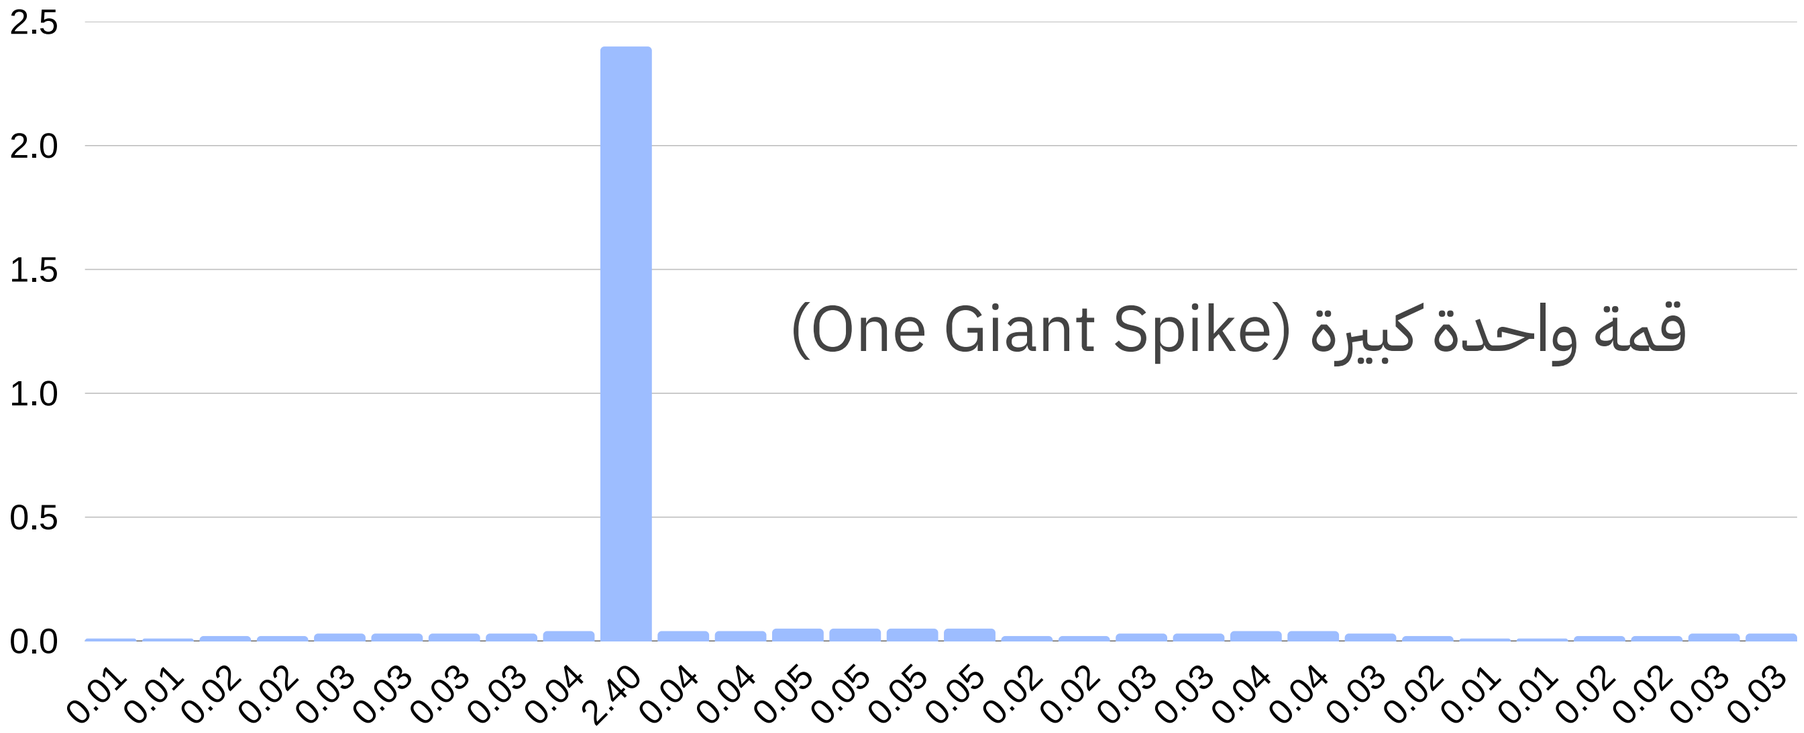

نشاط 3 | ⏳ دقيقة واحدة

ما المشكلة في هذا المدرج التكراري؟

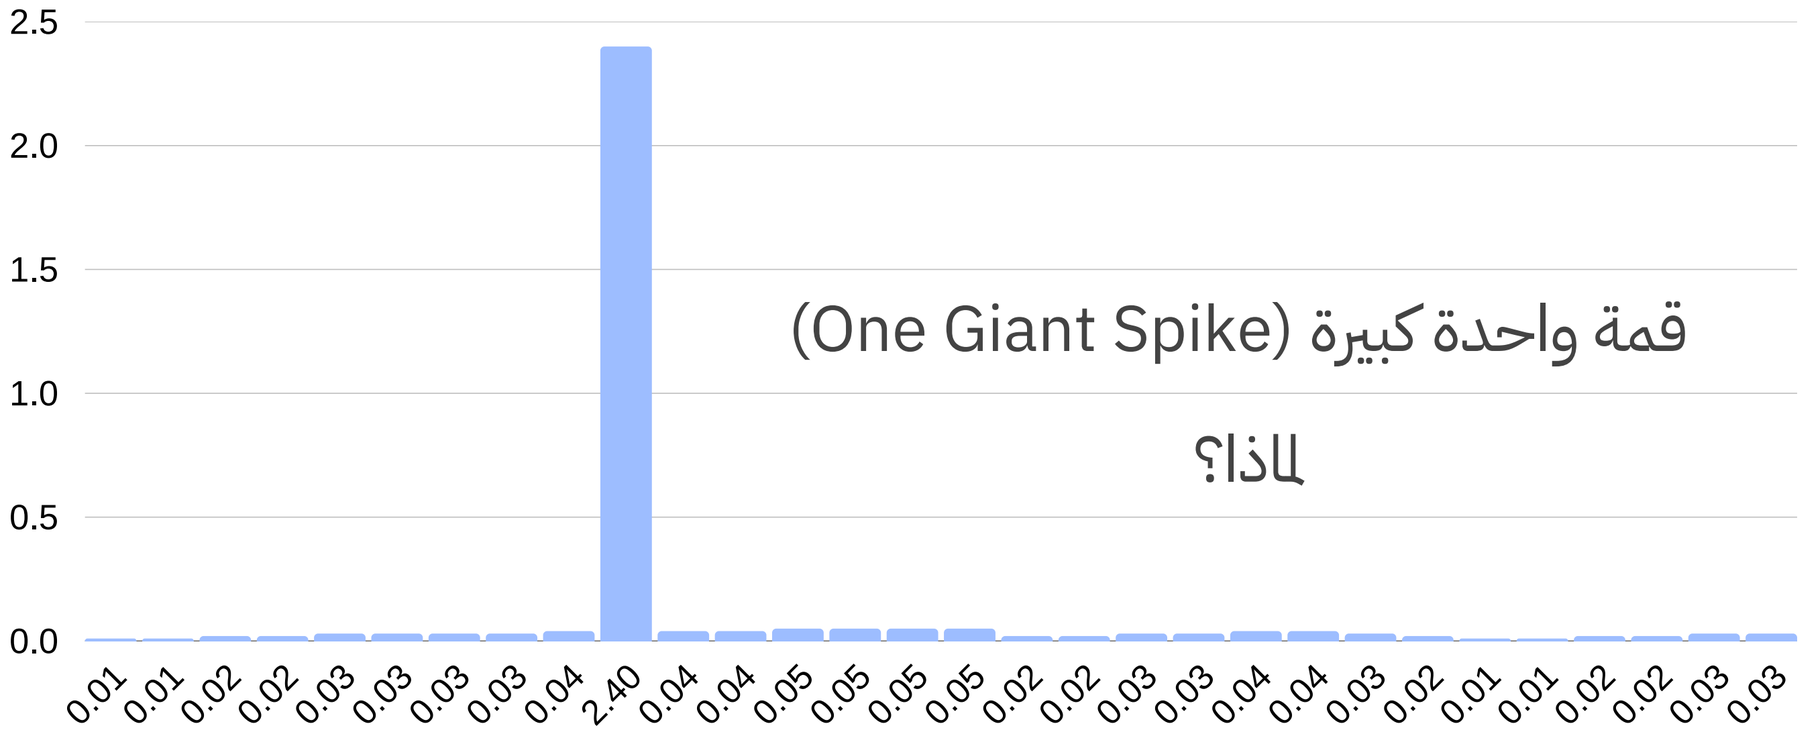

الإجابة:

تم تعويض جميع القيم المفقودة باستخدام المتوسط.

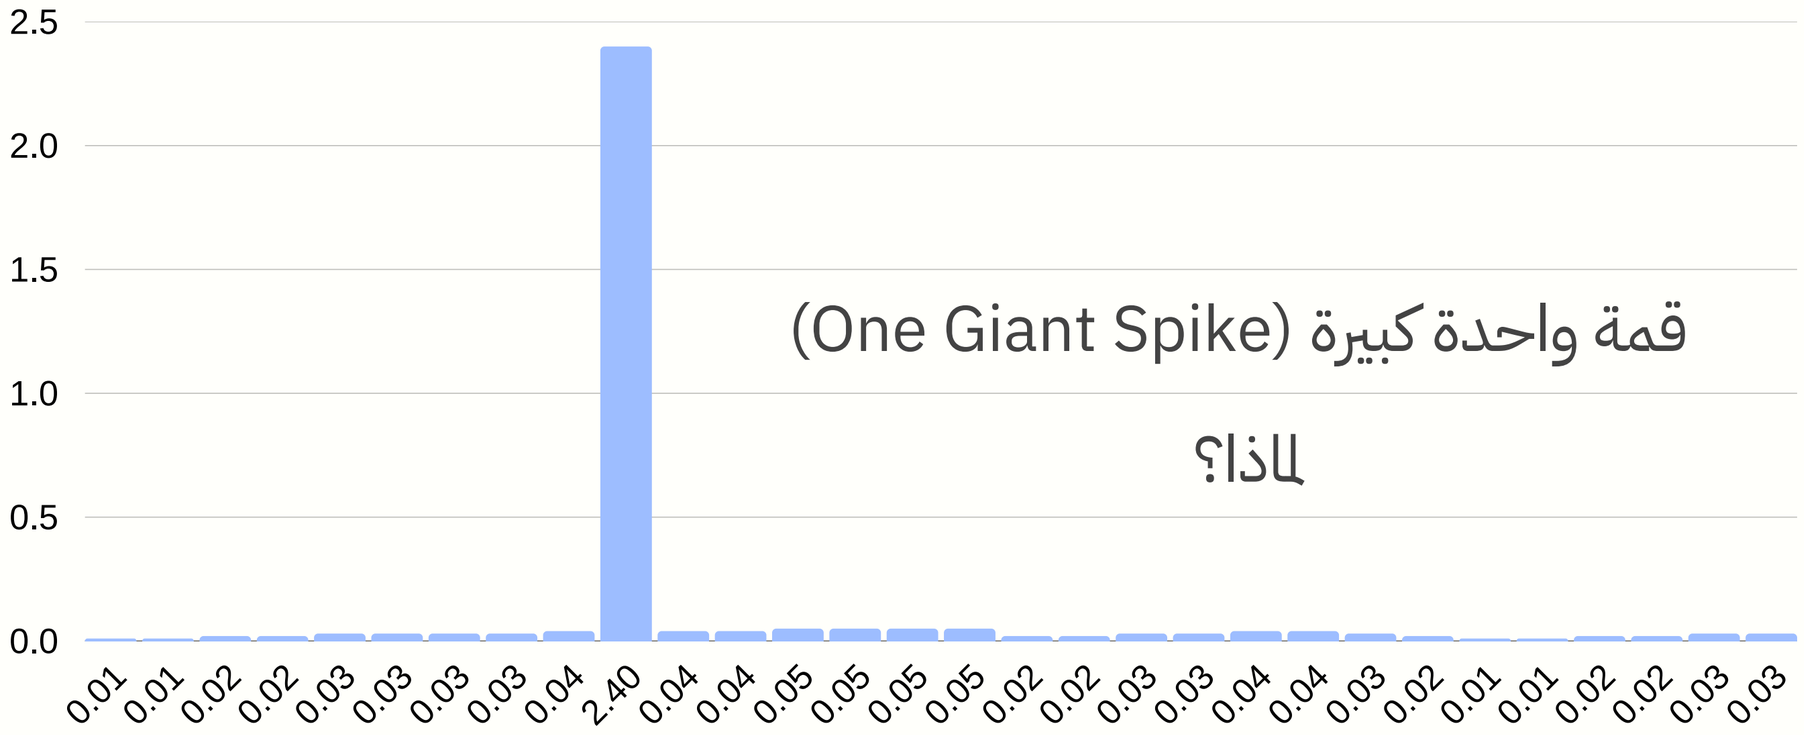

القيم الشاذة النقطية (Point Outliers)

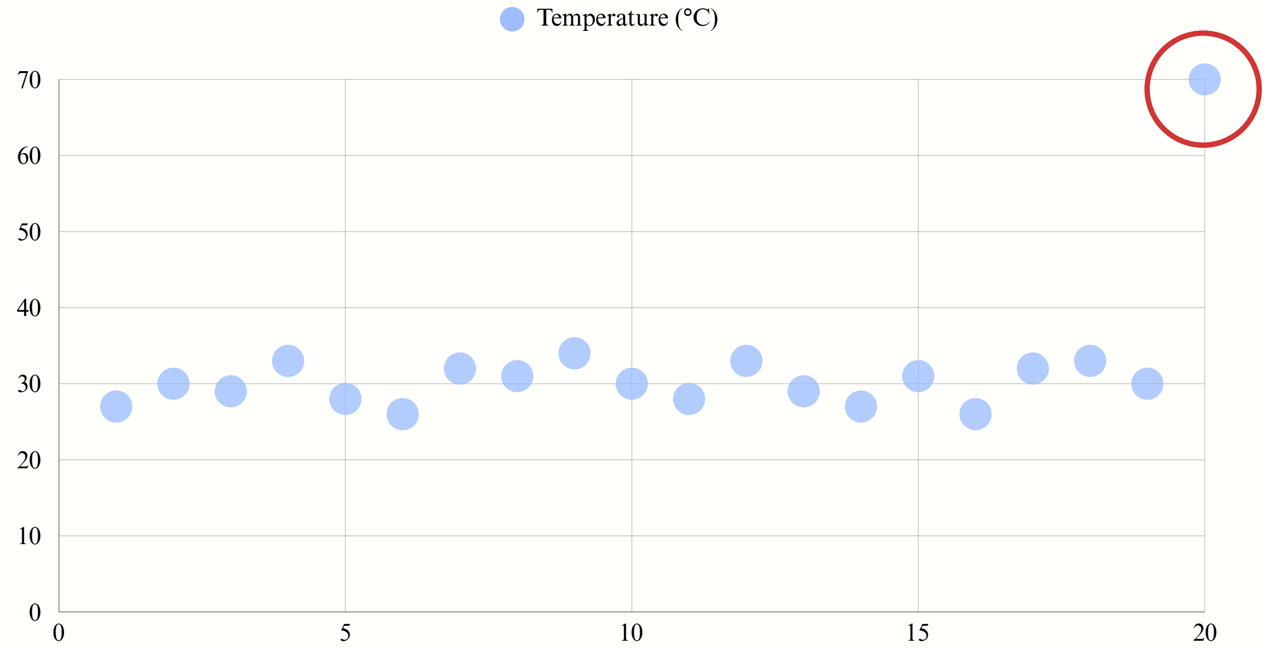

90% من درجات الحرارة تتراوح بين 25–35°C، بينما توجد قيمة واحدة تبلغ 70°C.

القيم الشاذة السياقية (Contextual Outliers)

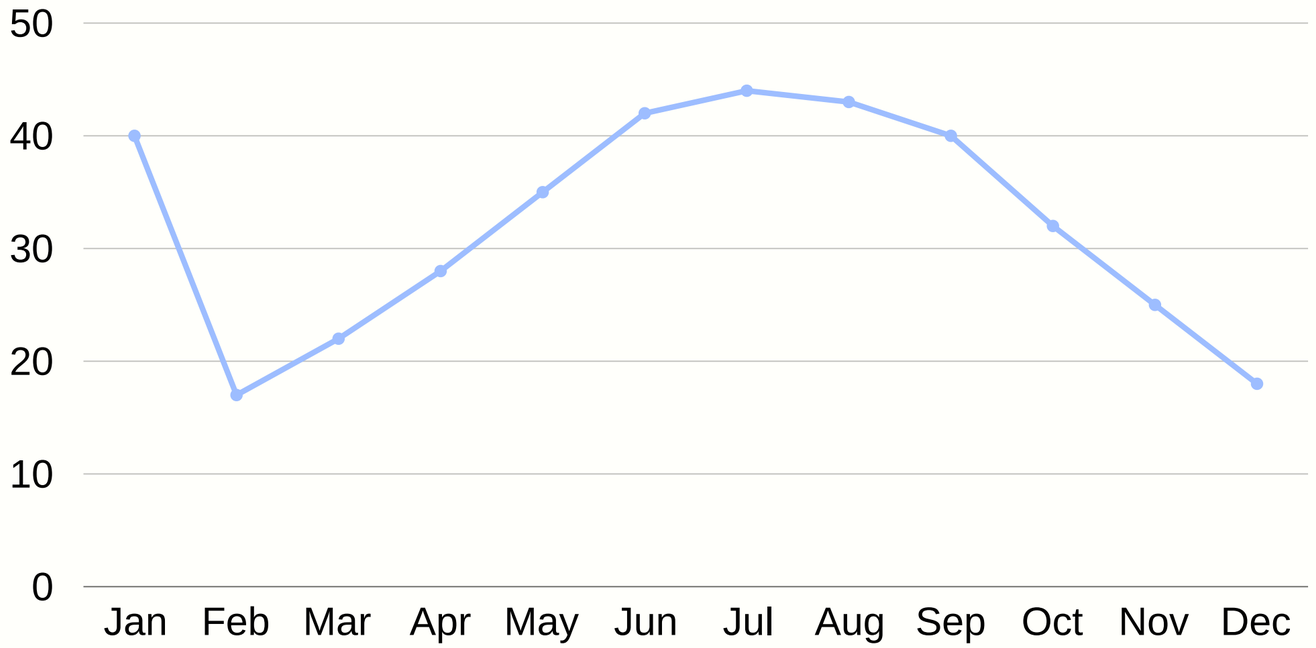

40°C درجة حرارة طبيعية في الرياض خلال فصل الصيف، لكنها تُعد قيمة شاذة في شهر يناير.

القيم الشاذة الجماعية (Collective Outliers)

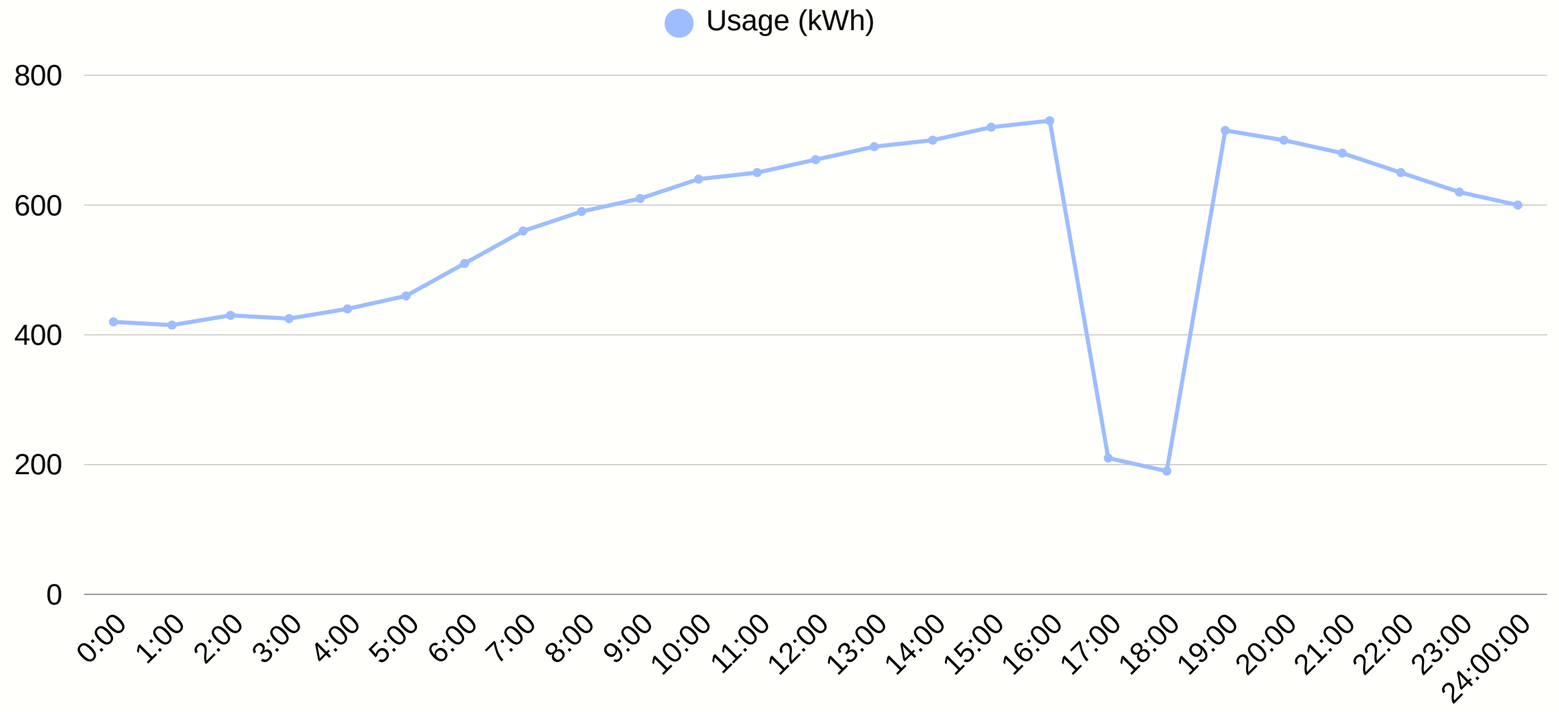

انخفاض مفاجئ في استهلاك الكهرباء لمدة ساعتين، وهو أمر غير معتاد عند النظر إلى هذه الفترة ككل.

القيم الشاذة المتطرفة (Extreme Value Outliers)

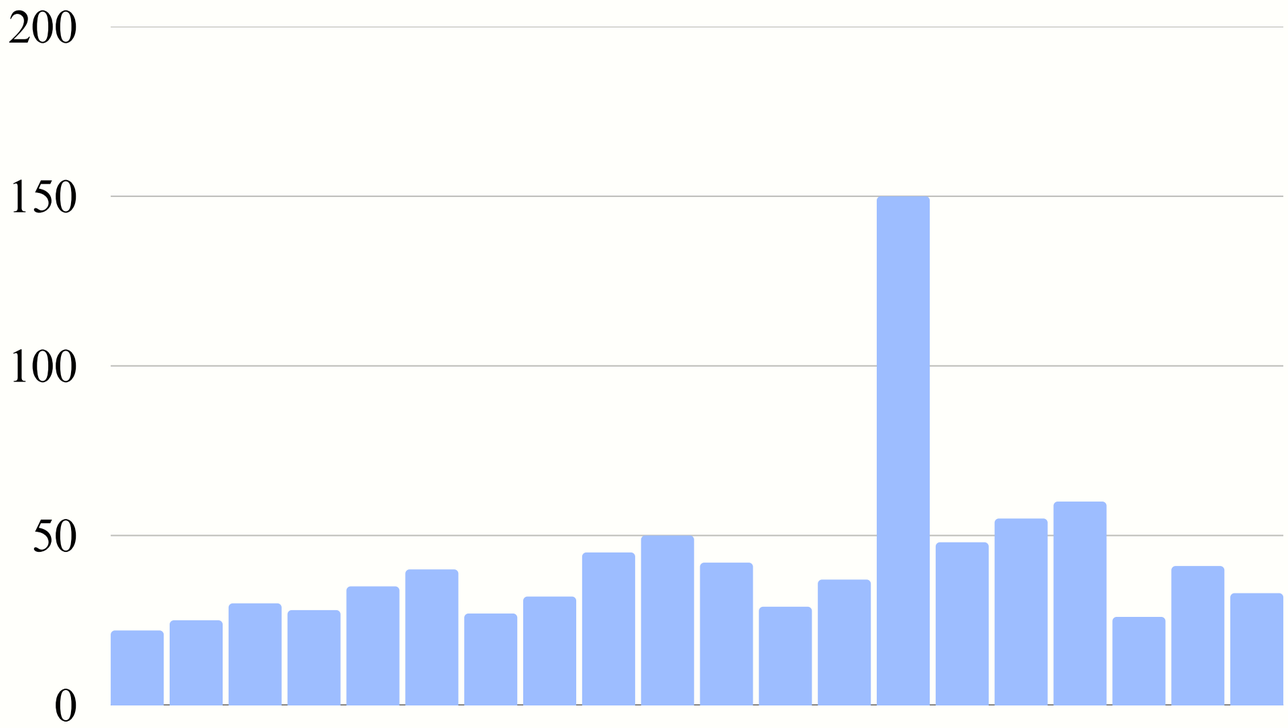

معظم القيم تتراوح بين 20 و60، بينما يُعد العمر 150 قيمة متطرفة.

القيم الشاذة الطبيعية (Natural Outliers)

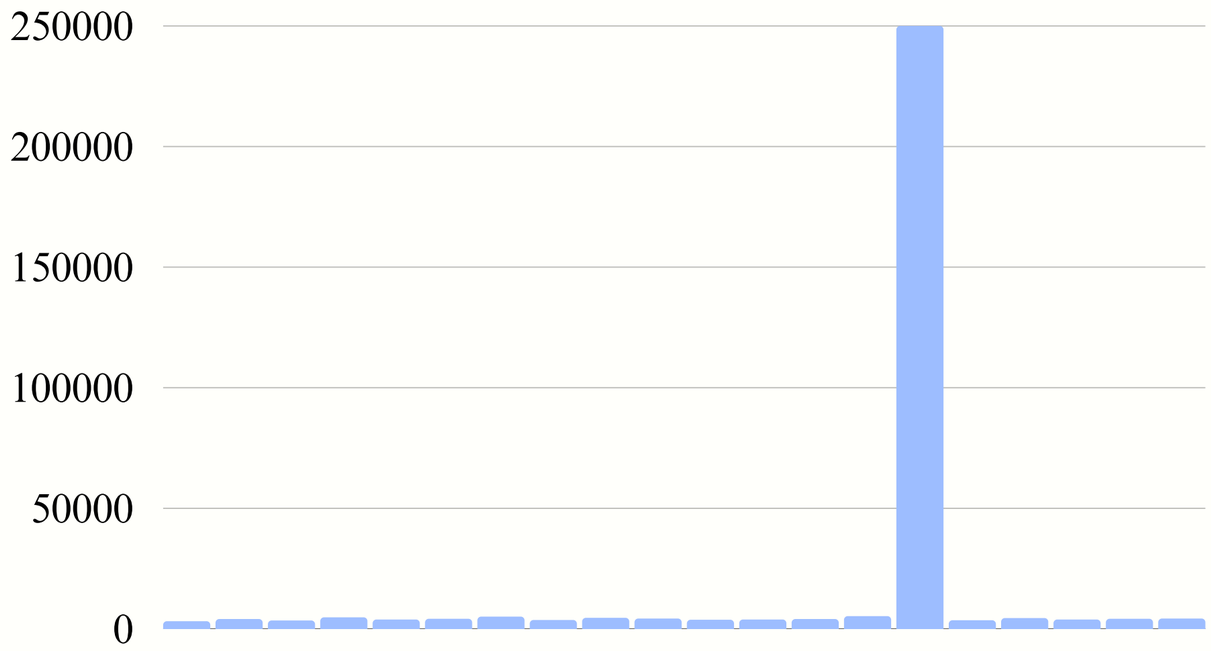

راتب مليونير ضمن بيانات رواتب لأفراد من الطبقة المتوسطة.

القيمة الشاذة الناتجة عن خطأ (Error Outlier)

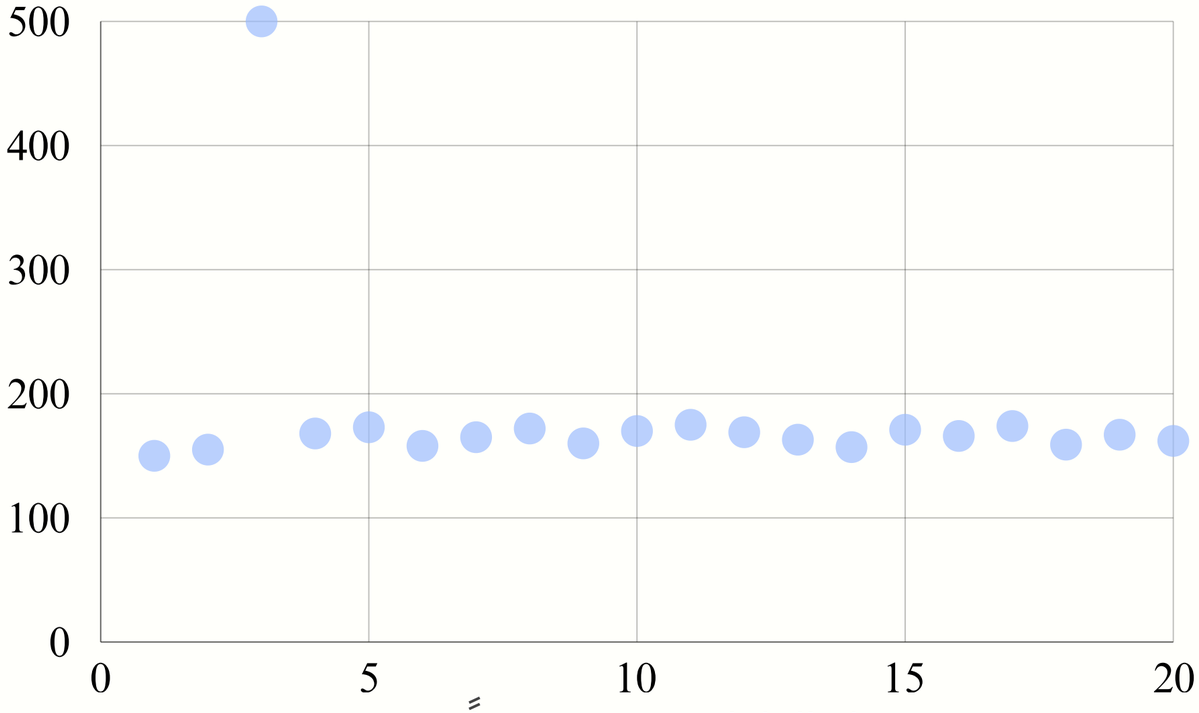

تم تسجيل الطول 500 سم بدلًا من 150 سم.

كيف تؤثر القيم الشاذة على سلوك نموذج تعلّم الآلة؟

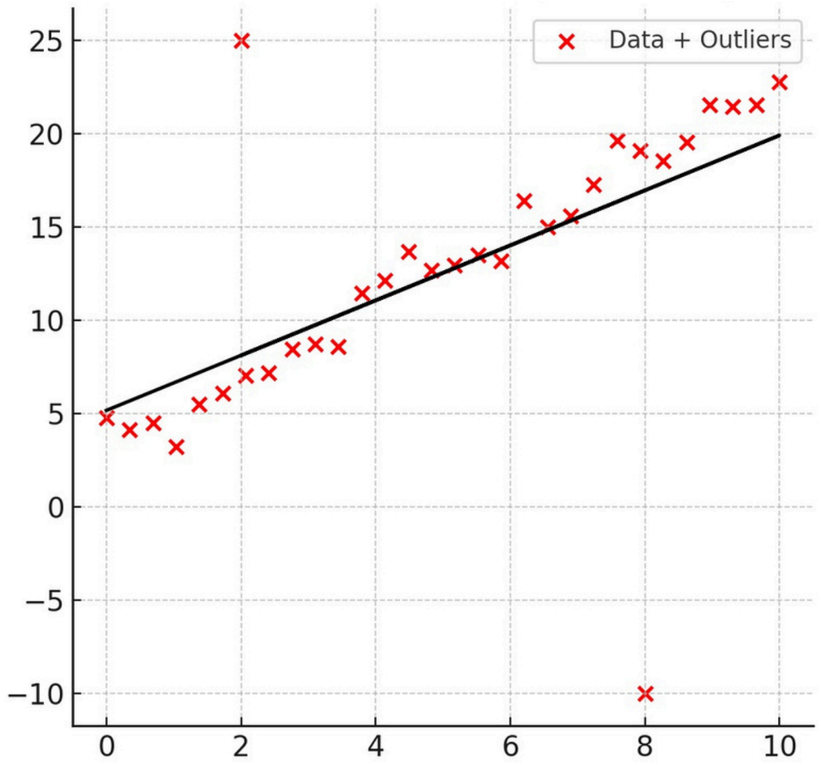

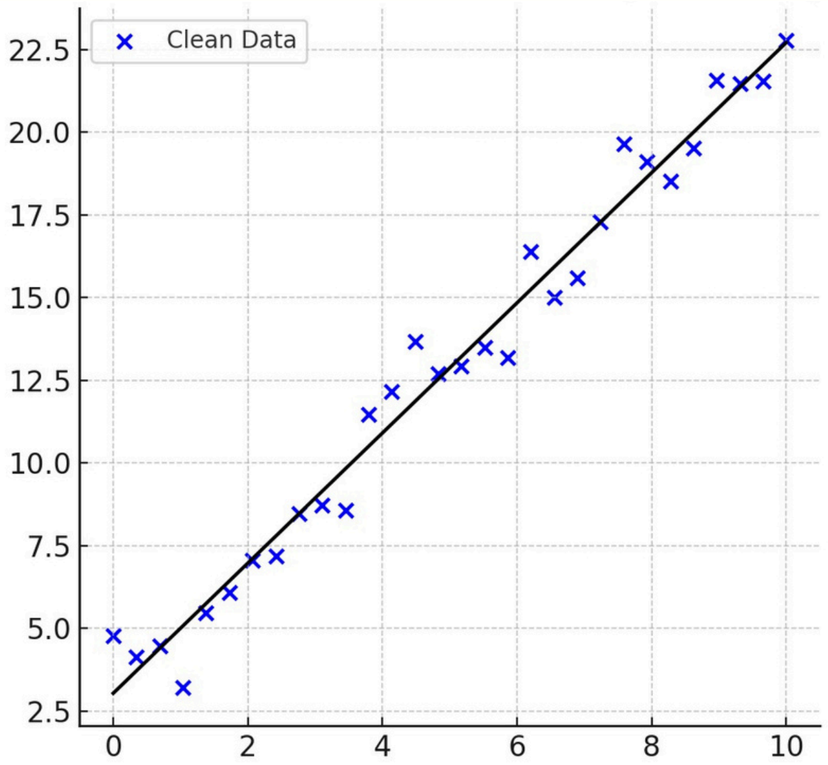

أكاديمية علو

نشاط عملي (Hands-On Activity)

Egypt Traffic Violations Dataset (2024)

تحتوي هذه المجموعة على سجلات واقعية لمخالفات المرور في مصر خلال عام 2024. وتشمل معلومات مثل أرقام لوحات المركبات، أنواع المخالفات المرورية، قيمة الغرامات، مواقع المخالفات، المدن، تواريخ تسجيل المخالفات، وحالة سداد الغرامة.

- افحص مجموعة البيانات بعناية، وبناءً على ملاحظاتك حدّد أي مشكلات أو تناقضات أو قيم غير طبيعية موجودة في البيانات.
- اقترح الخطوات المناسبة لتحسين جودة البيانات ومعالجة المشكلات التي حددتها في النشاط الأول، وذلك قبل إجراء أي تحليل للبيانات أو بناء نماذج تعلم آلي.

قبل ما نمشي

ايش أهم قرار هندسي بتأخذه بشكل مختلف بعد اليوم؟